

LIVE



#1

พื้นฐาน

รับชมฟรี

PYTHON

for Machine Learning

อัปเดตปี 2024



อาจารย์สาเมียร
สถาบันไอทีจีเนียส

8 JAN 2024 20.30-22.30 PM



สถาบันไอทีจีเนียส

วิทยาการ



อ.สามิตร ไกยม

ปริญญาโทคณะเทคโนโลยีสารสนเทศ

มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

► Frontend

Angular, React, NextJS, VueJS,
Bootstrap, TailwindCSS

► Backend

PHP, Python, Java, NodeJS, ASP.net

► Database

MySQL, PostgreSQL, MS SQL Server,
MongoDB

► Mobile

Java, Kotlin, Objective C, Swift, Cordova,
ionic, Flutter

► DevOps

Git, Github, Gitlab, Docker,
Kubernetes



Pre-Test




สถาบันไอทีจีเนียส


Pretest ทำแบบทดสอบก่อนอบรม

STEP 1: เข้าทำแบบทดสอบที่ลิงก์ ป้อนรหัสเข้าห้องสอบ

quizizz.com/join



STEP 2: ป้อนชื่อ



STEP 3: รอผู้สอน Start ป้อนสอบ



ดาวน์โหลดเอกสารประกอบการอบรม
bit.ly/livepythonml



สถาบันไอทีจีเนียส

Course Outline (7 days)

Python for Machine Learning

- Module 1:** เครื่องมือและสภาพแวดล้อม (Environment Setup)
- Module 2:** รู้จัก Data Science และ Machine Learning
- Module 3:** สร้างและจัดการอาร์เรย์ข้อมูลด้วยไลบรารี Numpy
- Module 4:** โหลดและจัดการชุดข้อมูลด้วยไลบรารี Pandas
- Module 5:** การพล็อตกราฟด้วยไลบรารี Matplotlib
- Module 6:** การจัดเตรียมข้อมูลสำหรับ Machine Learning
- Module 7:** โมเดล Linear Regression
- Module 8:** โมเดล Logistic Regression
- Module 9:** โมเดล Support Vector Machines (SVMs)
- Module 10:** โมเดล K-Nearest Neighbors



สถาบันไอทีจีเนียส

PYTHON

for Machine Learning

วันที่


1



อ.สาบิตร โทยม



สถาบันไอทีจีเนียส



Day 1

Python for Machine Learning

Module 1: การเตรียมเครื่องมือและสภาพแวดล้อม

Module 2: รู้จัก Data Science และ Machine Learning



สถาบันไอทีจีเนียส

Python Machine Learning ROADMAP


1. Setup tools and environment
2. Data Science and ML Overview
3. Stats & Probability
4. NumPy for Manage Array
5. Pandas for Data Manipulation
6. Matplotlib for Visualization
7. Machine Learning Concept
8. Linear Regression Model
9. Logistic Regression Model
10. Support Vector Machines (SVMS) Model
11. K-Nearest Neighbors
12. Deployment




Machine Learning ADVANTAGES



การรู้จำเสียง
Speech recognition
เทคโนโลยี NLP (Natural language processing) ในการแปลงจากเสียงพูดให้เป็นข้อความ




การให้บริการลูกค้า
แชทบอท AI
เข้ามาแทนที่พนักงานให้บริการใน Customer journey และเข้ามาเปลี่ยนวิธีการคิดเกี่ยวกับการสร้างความสัมพันธ์กับลูกค้าผ่านเว็บไซต์และโซเชียลมีเดีย



Computer vision

Computer vision สามารถที่จะเก็บชื่อคนบนรูปถ่ายในโซเชียลมีเดียได้
ถ่ายภาพรังสีวิทยาทางด้าน
การแพทย์ และรถยนต์ขับเคลื่อนอัตโนมัติในอุตสาหกรรมยานยนต์



ระบบการแนะนำ

Recommendation engine

อัลกอริทึม AI สามารถช่วยค้นพบเทรนด์ของข้อมูลที่น่าไปใช้ในกลยุทธ์ Cross-selling ได้ดียิ่งขึ้นโดยใช้ข้อมูลประวัติการซื้อสินค้าในอดีตมาวิเคราะห์ โดยธุรกิจค้าปลีกได้มีการนำวิธีการนี้ไปใช้งานเพื่อที่จะแนะนำสินค้าที่เกี่ยวข้องที่ลูกค้าน่าจะสนใจในขั้นตอนที่ลูกค้ากำลังจะชำระเงิน



Module 1

การเตรียมเครื่องมือและ สภาพแวดล้อม

- ติดตั้ง Python 3.x
- ติดตั้ง Editor ด้วย Visual Studio Code
- สร้าง Virtual Environment (venv) ในโปรเจกต์
- ติดตั้ง Python Jupyter notebook
- ทดสอบรันและใช้งาน Jupyter notebook

การเตรียมเครื่องมือ

PYTHON

for Machine Learning



อ.สาวิตร โทยม




System Requirement

- Windows 10 & 11 or
- MacOS 12.x +
- RAM 8 GB or upper
- CPU intel core i5 or upper
- HDD free space 10 GB or upper
- Access to internet



Tool & Editor to Install

1. Python 3.12.x on Windows and MacOS
2. Visual Studio Code (IDE)
3. Git





Python

- Python 3.12.x
<https://www.python.org/downloads/>

```
python --version
```

```
pip --version
```



- Python 3.12.x
<https://www.python.org/downloads/>

```
python3 --version
```

```
pip3 --version
```

- Visual Studio Code
<https://code.visualstudio.com/>

Tool & Editor

- Visual Studio Code
<https://code.visualstudio.com/>



ติดตั้ง Python 3.12.x บน Windows

Download Python | Python.org

python.org/downloads/

Python PSF Docs PyPI Jobs Community

python™

Donate Search GO Socialize

About Downloads Documentation Community Success Stories News Events

Download the latest version for Windows

[Download Python 3.12.1](#)

Looking for Python with a different OS? Python for [Windows](#), [Linux/UNIX](#), [macOS](#), [Other](#)

Want to help test development versions of Python 3.13? [Prereleases](#), [Docker images](#)

Join our year end fundraiser by donating or becoming a PSF Member! [Support the PSF](#)

Active Python Releases

For more information visit the [Python Developer's Guide](#).

Python version	Maintenance status	First released	End of support	Release schedule
3.13	prerelease	2024-10-01 (planned)	2029-10	PEP 719
https://www.python.org/ftp/python/3.12.1/python-3.12.1-amd64.exe		2023-10-02	2028-10	PEP 693

python.org/downloads

↓ > This PC > Local Disk (C:) > Users > samit > Downloads >

▼ Today (1)



python-3.12.1-amd64.exe

File description: Python 3.12.1 (64-bit)
Company: Python Software Foundation
File version: 3.12.1150.0
Date created: 8/1/2567 10:41
Size: 25.3 MB

▼ Yesterday (2)

Publisher: [Python Software Foundation](#)

Type: Application

From: C:\Users\samit\Downloads\python-3.7.3-amd64.exe


Run


Cancel


☒ Always ask before opening this file





While files from the Internet can be useful, this file type can potentially harm your computer. Only run software from publishers you trust. [What's the risk?](#)













ติดตั้ง Python 3.12.x บน MacOS

Files

Version	Operating System	Description	MD5 Sum	File Size	GPG	Sigstore
Gzipped source tarball	Source release		51c5c22dcbc698483734dff5c8028606	27053241	SIG	.sigstore
XZ compressed source tarball	Source release		50f827c800483776c8ef86e6a53831fa	20583448	SIG	.sigstore
macOS 64-bit universal2 installer	macOS	for macOS 10.9 and later	eae2d617cbd978a4a6c167924b287572	45377529	SIG	.sigstore
Windows embeddable package (32-bit)	Windows		acc28815c74facc402469e917c8f8433	9849182	SIG	.sigstore
Windows embeddable package (64-bit)	Windows		019788d34af2c60a7be45bf8273e361f	11061655	SIG	.sigstore
Windows embeddable package (ARM64)	Windows		18058aa3c8ccbf3e8fee53386d38c711	10277136	SIG	.sigstore
Windows installer (32-bit)	Windows		37a89a09138888e6331ec279d68fea8e	25253448	SIG	.sigstore
Windows installer (64-bit)	Windows	Recommended	3e3b6550e58772d324f7519bfa8066dc	26589696	SIG	.sigstore
Windows installer (ARM64)	Windows	Experimental	25fb741f175dc98d5630520f2df931ec	25806784	SIG	.sigstore


https://www.python.org/downloads/release/python-3121/





```
python3 --version
```

```
pip3 --version
```



ติดตั้ง Visual Studio Code



https://code.visualstudio.com

Read about the new features and fixes from November.

Code editing. Redefined.

Free. Open source. Runs everywhere.


Download for Windows

Stable Build



Other platforms and Insiders Edition

By using VS Code, you agree to its
license and privacy statement.



เข้าไปทำการดาวน์โหลด Visual Studio Code และติดตั้งไปตามขั้นตอนจนแล้วเสร็จ



IntelliSense



Debugging



Built-in Git



Extensions

Visual Studio Code

การติดตั้ง Extension

รายชื่อ Extensions สำหรับ Python



1. AutoFileName by JerryHong



2. Material Icon Theme by Philipp Kief



3. Python by Microsoft



4. Code Runner by Jun Han



5. Jupyter by Microsoft




6. One Dark Pro by binaryify



ติดตั้ง git




ดาวน์โหลดโปรแกรมได้ที่ www.git-scm.com





<https://git-scm.com/>



เลือกดังภาพ





เลือกดังภาพ





เลือกดังภาพ




เลือกดังภาพ



เลือกดังภาพ



หลังติดตั้งเสร็จ ทดสอบเปิด command prompt / terminal แล้วเรียกคำสั่ง **git version**



The image shows two terminal windows side-by-side. The left window is a Windows Command Prompt (cmd.exe) with a black background and white text. It shows the command 'git --version' being entered, followed by the output 'git version 2.21.0.windows.1'. The right window is a MINGW64 terminal with a dark blue background and white text. It shows the prompt 'samit@DESKTOP-5KFFN0F MINGW64 ~' followed by a dollar sign '\$' and a vertical line '|', indicating the command has been entered but not yet executed.

```
C:\Windows\system32\cmd.exe
C:\Users\samit>git --version
git version 2.21.0.windows.1
C:\Users\samit>_

MINGW64:/c/Users/samit
samit@DESKTOP-5KFFN0F MINGW64 ~
$ |
```

git version




Module 2

รู้จัก Data Science และ Machine Learning

- พื้นฐาน Data Science
- โครงสร้างข้อมูลแบบลำดับรายการของ Python
- ลักษณะของ Machine Learning
- หลักการทำนายผลของ Machine Learning
- โมเดลของ Machine Learning




Data Science (วิทยาการข้อมูล) คืออะไร



Data Science หมายถึง การนำข้อมูลมาใช้ประโยชน์ โดยครอบคลุมตั้งแต่ขั้นตอน

- การเก็บข้อมูล (Collect)
- การจัดการข้อมูล (Manage)
- การวิเคราะห์ข้อมูล (Analyze)
- การนำข้อมูลมาช่วยตัดสินใจ (Decision)


Data Science ประกอบด้วย Computer Science + Maths & Stats + Business Domain Expert ?



มีหลาย ๆ แห่งบอกว่าการทำ Data Science คือการที่ วงกลม 3 วงมาตัดกัน ได้แก่

- 1.Computer Science** – วิทยาการคอมพิวเตอร์ เช่น การเขียนโปรแกรม, อัลกอริธึม, โครงสร้างข้อมูล (Data Structure)
- 2.Maths & Statistics** – คณิตศาสตร์ และสถิติ
- 3.Business / Domain Expertise** – ความรู้ด้านธุรกิจ

ตำแหน่งงานและทักษะสำคัญต่อการทำงานด้าน Data Science



Data Engineer

ทำอะไร ?

สร้างระบบสำหรับส่งข้อมูล (Data Pipeline) และจัดเก็บข้อมูล (Data Storage) เพื่อให้ตำแหน่งงานอื่นๆ สามารถนำไปใช้ได้สะดวก

ความรู้ที่ต้องใช้ ?

- Database (SQL)
- Data Warehouse
- Big Data Infrastructure
- Cloud Computing
- Programming




Data Scientist

ทำอะไร ?

สร้างโมเดลทำนายผล ด้วยข้อมูลทางสถิติ (Statistical Modelling) , Machine Learning หรือ Deep Learning

ความรู้ที่ต้องใช้ ?

- Math
- Statistics
- Learning Algorithms
- Neural Networks
- Programming




Data Analyst

ทำอะไร ?

วิเคราะห์ข้อมูลเพื่อหาสิ่งที่ซ่อนอยู่ (Data Insight) ในข้อมูลด้วยเทคนิคต่างๆ ทางด้านสถิติ และ Visualization เพื่อนำมาต่อยอดทางธุรกิจ

ความรู้ที่ต้องใช้ ?

- Business Model
- Statistics
- Spreadsheet Tools
- Data Visualization
- SQL



RAPIDMINER



+ a b l e a u



Looker Studio





python™



NumPy








	ธุรกิจ	สื่อสาร	สถิติ	คอมพิวเตอร์
ธุรกิจ	นักบัญชี	นักขาย	นักวิเคราะห์	IT
สื่อสาร		พิธีกร, ดีเจ	อาจารย์	อาจารย์
สถิติ			นักสถิติ	R
คอมพิวเตอร์				Programmer

AI

ปัญญาประดิษฐ์ (Artificial Intelligence) คือศาสตร์ที่ต้องการสร้างคอมพิวเตอร์ให้มีความฉลาดหรือสติปัญญาในลักษณะเดียวกับมนุษย์

Machine Learning

คือการจำลองความฉลาดประเภทหนึ่งของมนุษย์ นั่นคือ “การที่มนุษย์สามารถเรียนรู้ความรู้เพิ่มเติมได้ตลอด”




Deep Learning

คือ โมเดลประเภทหนึ่งของ Machine Learning ที่ประสบความสำเร็จสูงสุดในปัจจุบัน (2018) ที่มีรากฐานจากการจำลองสมการคณิตศาสตร์ของเซลล์สมองของมนุษย์

ARTIFICIAL INTELLIGENCE

Early artificial intelligence stirs excitement.



MACHINE LEARNING

Machine learning begins to flourish.



DEEP LEARNING

Deep learning breakthroughs drive AI boom.



1950

1960

1970

1980

1990

2000

2010



Manufacturing

- Predictive maintenance or condition monitoring
- Warranty reserve estimation
- Propensity to buy
- Demand forecasting
- Process optimization
- Telematics



Travel and Hospitality

- Aircraft scheduling
- Dynamic pricing
- Social media – consumer feedback and interaction analysis
- Customer complaint resolution
- Traffic patterns and congestion management



Retail

- Predictive inventory planning
- Recommendation engines
- Upsell and cross-channel marketing
- Market segmentation and targeting
- Customer ROI and lifetime value



Financial Services

- Risk analytics and regulation
- Customer Segmentation
- Cross-selling and up-selling
- Sales and marketing campaign management
- Credit worthiness evaluation



Healthcare and Life Sciences

- Alerts and diagnostics from real-time patient data
- Disease identification and risk stratification
- Patient triage optimization
- Proactive health management
- Healthcare provider sentiment analysis



Energy, Feedstock and Utilities

- Power usage analytics
- Seismic data processing
- Carbon emissions and trading
- Customer-specific pricing
- Smart grid management
- Energy demand and supply optimization

*Machine Learning is
using **data** to
answer questions*



Machine Learning

การใช้ **ข้อมูล**
เพื่อ **ตอบคำถาม**



Data



Training



Model

การใช้ข้อมูล
ตอบคำถาม



*answer
questions*





Serve Predictions

Machine Learning (ML)

Machine Learning (ML) คือองค์ประกอบส่วนหนึ่งของ AI หรือปัญญาประดิษฐ์ (Artificial Intelligence : AI) ที่มีความสำคัญอย่างยิ่ง เพราะเป็นส่วนที่ใช้ในการคิดและตัดสินใจ หรืออาจกล่าวได้ว่า Machine Learning ก็คือสมองของ AI นั่นเอง




Machine Learning vs Deep Learning




Traditional Program vs Machine Learning

Machine Learning เราไม่ได้ Program คำตอบ เราใส่ Data และ Output (ผลลัพธ์) เข้าไป เพื่อให้หา Program ที่จะนำไปตอบในอนาคตได้ว่า Input แบบนี้ Output จะเป็นอะไร


Traditional Programming




Machine Learning




Using a printed adversarial patch to fool an AI system



<https://www.youtube.com/watch?v=MibFvK2S9g8>



Machine Learning มีอะไรบ้าง มีกี่แบบ




- 1.Supervised Learning** – เรียนรู้โดยมี data มาสอน
- 2.Unsupervised Learning** – เรียนรู้โดยไม่มี data สอน
- 3.Reinforcement Learning** – เรียนรู้ตามสภาพแวดล้อม

Supervised Learning

คือการเรียนรู้ โดยมี data มาสอน ชัดๆ เลยก็คือ เด็กน้อยต้องไปสอบแยกแยะประเภทหมาแมว เราจึงชี้ให้เด็กน้อย รู้จักแมว ชี้ให้รู้จักหมา หลายๆ ครั้งจนเด็กจำได้

Data Scientist จึงต้องสร้าง Model ที่จะทำให้คอมพิวเตอร์รู้จักหมาแมวเข้าไป โดยเอาข้อมูลหมาแมวใส่เข้าไปเช่น ใส่สี ใส่ลักษณะ ของแมวแต่ละตัวเข้าไป โดยแปลงให้เป็นภาษาคอมพิวเตอร์ หรือเป็นตัวเลขนั่นเอง (เราเรียกมันว่า features) พร้อมเฉลยไว้เลยว่า นี่คือแมว !! โดยใส่ข้อมูลเป็นตัวเลข (เราเรียกมันว่า labels)

Supervised Learning



Adapted from P.Vincent http://videlectures.net/deeplearning2015_vincent_machine_learning/


หลังจากนั้นเราก็เอา แมวมาให้ คอมพิวเตอร์ดู แล้วให้ตอบว่า นี่อะไร? คอมพิวเตอร์ก็ดูจาก features ที่ใส่ไปให้ และสามารถ Predict หรือตอบได้ว่า นี่คือแมว !!

Process การ Train และ Predict จะเป็นสิ่งที่ต้องทำเสมอในการทำ Machine Learning Model

การใส่ features ของภาพและวิธีการในการแยกแยะ ก็จะเป็นเรื่อง convolutional neural network

Supervised Learning

ที่ใช้กันบ่อยโดยไม่รู้ตัวว่าเป็น Machine Learning คือการรัน Regression



และแบบอื่นๆ

- Support vector machine
- Naive Bayes
- Gradient boosting
- Classification trees / random forest

Unsupervised Learning

Unsupervised Learning นั้นตรงกันข้ามกับ Supervised Learning คือไม่มี Data มาสอน ถ้าให้เทียบก็คือ ไม่บอกเด็กน้อยแล้วว่า นี่คือหมาหรือแมว แต่ให้เด็กแยแยะแยะได้เอง

แยกแยะเองได้อย่างไร?

เด็กน้อยก็จะสังเกตรูปร่างหน้าตาของแมวได้ รูปร่างหน้าตาของหมาได้ ว่ามันไม่เหมือนกัน แต่ในทางปฏิบัตินั้นยาก


สมมติว่าต้องมีแมว 3 สายพันธุ์ จะแยกง่ายสุดทำอย่างไร?

ก็แยกตามขนาด น้ำหนัก และส่วนสูง

สายพันธุ์เดียวกัน ที่อายุพอๆกัน ก็ควรจะเกาะกลุ่มกัน ก็จะแบ่งได้ดังรูป

Model ที่จะหาตัวนี้ก็มีมากมาย ตัวอย่างโมเดลที่ง่ายที่สุด ก็จะเป็นการพยายามหาระยะห่างจากจุดๆหนึ่งไปอีกจุดหนึ่ง ก็จะได้การกระจุกตัวนั่นเอง


- K Nearest Neighbor
- K Mean



Reinforcement Learning

ในบรรดา Machine Learning ทั้งหมด Reinforcement Learning คือสิ่งที่ดูเป็น Artificial Intelligence (AI) ที่แท้จริง ที่สุด เพราะจะเรียนรู้และเปลี่ยนไปตามสิ่งแวดล้อม

เข้าใจง่ายที่สุด ให้นึกถึงเวลา เด็ก ฝึกเดิน



ในการเดินแต่ละครั้ง มีหลายปัจจัยที่ต้องคิด ที่เด็กน้อยจะต้องทำให้ได้คือ ยืนอย่างไร พื้นเสมอหรือไม่ ทิ้งน้ำหนักตัวตรงไหน ทางแขนท่อนศอก ก้าวเท้าระยะเท่าไร ยกขาสูงแค่ไหน



มันดูยากมากสำหรับเด็กน้อย ก็ต้องทดลองเดิน ไปเรื่อย ๆ

และให้รางวัลเด็กน้อยเป็นช็อคโกแลต เมื่อเด็กเดินสำเร็จ แต่ถ้าไม่เดินก็ไม่ให้รางวัล เด็กน้อยก็จะเข้าใจว่า แบบนี้ดี แบบนี้ไม่ดี อีกตัวอย่างหนึ่งที่ชัดคือการฝึกสัตว์เลี้ยง

วิธีนี้เหมาะสมกับโจทย์บางประเภท คือการหากลยุทธ์ที่ทำให้ชนะเกม เช่น เดินออกจากเขาวงกต

- Markov Decision Processes (MDP)
- Q-learning

Reinforcement Learning



<https://www.youtube.com/watch?v=qv6UVOQ0F44>

Algorithms menu

- Linear Regression
- k-Means
- k-NN
- SVM
- Decision Trees
- Random Forests
- Naive Bayes
- Logistic Regression
- Neural Networks




เส้นทางการเรียนรู้ของ Machine Learning



12 Steps of ML/AI

1. Objective & criteria
2. Data collection
3. Data splitting
4. Exploration
5. Algorithms
6. Training
7. Tuning & debugging
8. Validation
9. Testing
10. Productionization
11. Launch decision
12. Monitoring & maintenance



LIVE



#2

พื้นฐาน

รับชมฟรี

PYTHON

for Machine Learning

อัปเดตปี 2024



อาจารย์สามิตร
สถาบันไอทีจีเนียส

15 JAN 2024 20.30-22.30 PM



สถาบันไอทีจีเนียส



PYTHON

for Machine Learning

วันที่


2



อ.สาวิตร โทยม



สถาบันไอทีจีเนียส



Day 2

Python for Machine Learning


Module 3: สร้างและจัดการอาร์เรย์ข้อมูลด้วยไลบรารี Numpy

Module 4: โหลดและจัดการชุดข้อมูลด้วยไลบรารี Pandas

Module 5: การพล็อตกราฟด้วยไลบรารี Matplotlib

Statistics for Data Science








ประชากร vs กลุ่มตัวอย่าง (Population vs Sample)

ประชากรก็คือจำนวนผู้ถูกสำรวจ (Observation) ทั้งหมดในเรื่องที่เราต้องการที่จะศึกษา เช่น

“ถ้าเราอยากรู้ว่าคนทั้งโลกนี้มีอายุเฉลี่ยแล้วเท่าไร?”

การที่เราเก็บข้อมูลมาจากคนทั้งโลกเพื่อหาค่าเฉลี่ยของอายุนั้นแหละคือประชากร (ประมาณ 7.6 พันล้านคน!!!)


แต่ในความเป็นจริงหากให้เราเก็บข้อมูลคนทั้งโลกก็คงไม่ไหว เพราะคนมีเยอะมาก ใช้เวลาและทรัพยากรในการเก็บนาน และมีปริมาณเปลี่ยนแปลง (เกิด-ตาย) ไปตลอดเวลา ดังนั้นถ้าหากเราเปลี่ยนเป็นเก็บข้อมูลประเทศละ 1,000 คน โดยที่ตอนนี้มีจำนวนประเทศทั้งหมด 195 ประเทศ เราก็จะได้กลุ่มตัวอย่าง $1,000 * 195 = 195,000$ คน ก็อาจจะเพียงพอแล้วต่อการอธิบายค่าเฉลี่ยอายุของคนทั้งโลก





ประเภทของข้อมูล (Types of Data)

เราได้ทำความรู้จักกับประเภทของผู้ถูกสำรวจไปแล้ว ต่อไปจะเป็นประเภทของข้อมูลกันบ้างครับ โดยผมจะให้ดู Mind Map การแบ่งประเภทของข้อมูลเพื่อทำความเข้าใจ Concept และนึกภาพตามไปพร้อมกัน



ข้อมูลที่เราเก็บมาได้นั้นจะแบ่งออกเป็น 2 ประเภท

- ข้อมูลเชิงปริมาณ (Quantitative Data/Numerical Data)** — เป็นข้อมูลที่สามารถนำมาวิเคราะห์เชิงคณิตศาสตร์ได้...มันคือข้อมูลที่สามารถวัดค่าออกมาได้ เช่น ค่าความยาว, ความสูง, อายุ, รายได้ เป็นต้น
- ข้อมูลเชิงคุณภาพ (Qualitative Data/Categorical Data)** — มันก็คือข้อมูลที่ไม่สามารถนำมาวิเคราะห์เชิงคณิตศาสตร์ได้นั่นเอง เช่น สี, ระดับการศึกษา, ธรรมชาติ เป็นต้น



การวัดแนวโน้มเข้าสู่ส่วนกลาง (Measures of Central Tendency)

เมื่อเราทราบถึงประเภทของข้อมูลแล้ว ต่อไปจะเป็นส่วนของการวิเคราะห์ข้อมูล โดยในทางสถิตินั้นเราจะใช้ตัวเลขที่เป็นตัวแทนในการอธิบายข้อมูลทั้งชุด ซึ่ง **Central Tendency** ก็คือการใช้ค่ากลางเป็นตัวแทนของข้อมูล

โดยค่ากลางของข้อมูลในทางสถิติจะใช้กัน 3 ค่า นั่นคือ

$$\text{Mean} = \frac{\text{Sum of all values}}{\text{Total number of all values}}$$

$$\text{Median} = \text{Middle value (when the data are arranged in order)}$$

$$\text{Mode} = \text{Most common value}$$

1. ค่าเฉลี่ย (Mean) — ผลรวมของชุดข้อมูลหารด้วยจำนวนข้อมูลที่มีทั้งหมด
2. มัธยฐาน (Median) — ค่าที่อยู่ตรงกลางของชุดข้อมูล หลังจากทำการเรียงลำดับข้อมูลแล้ว
3. ฐานนิยม (Mode) — ค่าที่เกิดขึ้นบ่อยที่สุดในชุดข้อมูล

Mean

Add up all the data points and then divide by the total number of numbers.

$$\begin{aligned} &1, 2, 3, 4, 5 \\ &1 + 2 + 3 + 4 + 5 = 15 \\ &15 \div 5 = 3 \end{aligned}$$

Median

The middle value, the midpoint of the data when arranged in order.

$$\begin{aligned} &5, 3, 4, 2, 1 \\ &1, 2, 3, 4, 5 \\ &= 3 \end{aligned}$$

Mode

The value that appears the most often.

$$\begin{aligned} &5, 1, 3, 4, 2, 1 \\ &= 1 \end{aligned}$$



การวัดการกระจาย (Measure of Dispersion)

และเช่นเดียวกันกับ Measure of Dispersion นั้นคือการใช้ค่าการกระจายเป็นตัวแทนในการแสดงความผันผวนของข้อมูลนั่นเอง

โดยวิธีที่นิยมใช้ก็คือ

1. พิสัย (Range) — ผลต่างระหว่างค่าที่เยอะที่สุดกับค่าน้อยที่สุด
2. ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) — ผลต่างของข้อมูลทุกค่ากับค่าเฉลี่ย
3. ความแปรปรวน (Variance) — มันก็คือส่วนเบี่ยงเบนมาตรฐานยกกำลังสองเพื่อขจัดหน่วยของตัวแปร

Variance

Population

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

Standard deviation

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

Sample

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$


Standard Deviation

$$\sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

76	84	69	92	58
89	73	97	85	77

$$\sqrt{137.19} \approx 11.70$$

$$\bar{X} = \frac{\text{Sum}}{n} = 80$$



ความน่าจะเป็น (Probability)

ความน่าจะเป็น ก็คือ “โอกาสที่เหตุการณ์ที่เราสนใจจะเกิดขึ้น” เช่น

“หากเราสนใจว่าการทอยลูกเต๋า 1 ครั้งจะเป็นเลข 4 มีโอกาสเท่าไร?”


สูตรในการหาค่าความน่าจะเป็นก็คือ

$$P(A) = \frac{\text{Events}}{\# \text{ of Outcomes}}$$

โดย $P(A)$ คือความน่าจะเป็นของเหตุการณ์ A เท่ากับ Events ก็คือเหตุการณ์ที่เราสนใจหารด้วย จำนวน Outcomes (Sample Space) ก็คือผลลัพธ์ที่สามารถเกิดขึ้นทั้งหมด



เพราะฉะนั้นการทอยลูกเต๋าก็ได้เลข 4 นั้นมีโอกาสคือ 1 ใน 6 หรือ $1/6 \approx$ ร้อยละ 0.167 หมายความว่าโดยเฉลี่ย(ไม่จำเป็นจะต้องเกิดขึ้นทุกครั้ง!!!)แล้วการทอยเต๋า 6 ครั้ง อาจจะทอยได้เลข 4 จำนวนหนึ่งครั้งนั่นเอง



ความน่าจะเป็น (Probability)

แต่ถ้าในชีวิตจริง เราอาจจะเกิดความน่าจะเป็นที่ซับซ้อนกว่านี้ เหตุการณ์แรกอาจมีความสัมพันธ์กับเหตุการณ์ถัดๆ ไป ดังนั้นสิ่งต่อไปที่เราจะต้องทราบนั้นก็คือ Conditional Probability ด้วย


Conditional Probability


ความหมายของมันก็คือ ความน่าจะเป็นที่เกิดขึ้นเมื่อเกิด Events ก่อนหน้า ดังนั้นหมายความว่าทั้งสองเหตุการณ์นั้นจะต้องมีความสัมพันธ์กัน เช่น

“ความน่าจะเป็นเมื่อหยิบลูกบอลครั้งแรกได้สีแดงแล้วครั้งที่สองเป็นสีเขียว (แบบหยิบแล้วไม่ใส่คืน)”

สูตรของ Conditional Probability คือ

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$






ความน่าจะเป็น (Probability)


“ความน่าจะเป็นเมื่อหยิบลูกบอลครั้งแรกได้สีแดงแล้วครั้งที่สองเป็นสีเขียว (แบบหยิบแล้วไม่ใส่คืน)”

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

สัญลักษณ์ของ Conditional Probability คือ **P(B|A)** หมายถึง ความน่าจะเป็นที่จะเกิดเหตุการณ์ B เมื่อเกิดเหตุการณ์ A ขึ้น จะเท่ากับ ความน่าจะเป็นที่จะเกิดขึ้นทั้งสองเหตุการณ์ **P(A∩B)** หารด้วยความน่าจะเป็นของเหตุการณ์ **A P(A)**

เครื่องหมาย / จะอ่านว่า “Given” และเครื่องหมาย ∩ อ่านว่า “และ (And)”





ความน่าจะเป็น (Probability)


“ความน่าจะเป็นเมื่อหยิบลูกบอลครั้งแรกได้สีแดงแล้วครั้งที่สองเป็นสีเขียว (แบบหยิบแล้วไม่ใส่คืน)”


$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

โจทย์ด้านบนจะพบว่า A คือการหยิบลูกบอลครั้งแรกแล้วได้สีแดง และ B คือการหยิบลูกบอลครั้งที่สองแล้วได้สีเขียวนั่นเอง

P(หยิบลูกบอลครั้งแรก) ก็คือความน่าจะเป็นที่จะหยิบลูกบอลครั้งแรกแล้วได้สีแดงมีค่าเท่ากับ $15/22 \approx 0.682$

P(หยิบลูกบอลครั้งที่สอง|หยิบลูกบอลครั้งแรก) จะมีค่าเท่ากับ $1/21 \approx 0.048$ เนื่องจากในตอนแรกมีลูกบอลในกล่องทั้งหมด 22 ลูก แต่การหยิบครั้งที่สองนั้นจำนวนลูกบอลสีแดงลดลงไป 1 ลูกทำให้ Sample Space ครั้งที่สองลดลงเป็นการสุ่มจากลูกบอลในกล่องเพียง 21 ลูก โดยมีลูกบอลสีเขียวในกล่องเพียง 1 ลูก





ความน่าจะเป็น (Probability)


“ความน่าจะเป็นเมื่อหยิบลูกบอลครั้งแรกได้สีแดงแล้วครั้งที่สองเป็นสีเขียว (แบบหยิบแล้วไม่ใส่คืน)”

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

เราก็จะสามารถหาความน่าจะเป็นที่จะเกิดขึ้นทั้งสองเหตุการณ์ $P(A \cap B)$ ได้โดยการย้ายข้างสูตรข้างบนเป็น

$$P(A \cap B) = P(A) * P(B|A)$$

$P(\text{หยิบลูกบอลครั้งแรก} \cap \text{หยิบลูกบอลครั้งที่สอง}) = 0.682 * 0.048 \approx 0.033$ หรือประมาณ **3.3%** ที่เหตุการณ์นี้จะเกิดขึ้น





Bayes Theorem

Bayes Theorem คือการนำ Conditional Probability มาประยุกต์ใช้ในการทำนายความน่าจะเป็นของเหตุการณ์ที่จะเกิดขึ้น โดยมีสูตรมาจาก

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$


- **P(A|B)** คือผลลัพธ์ของการทำนาย เราเรียกมันว่า Posterier
- **P(B|A)** คือการตัดสินใจเมื่อเกิดเหตุการณ์ขึ้น เราเรียกมันว่า Likelihood
- **P(A)** คือความรู้ที่มีอยู่แล้ว เราเรียกมันว่า Prior Knowledge
- และ **P(B)** คือโอกาสที่จะเห็นเหตุการณ์นั้น เราเรียกมันว่า Evidence

Conditional Probability และ **Bayes Theorem** ถูกนำไปประยุกต์ใช้ในการทำนายผลของ Machine Learning ได้หลายรูปแบบ เช่น การทำนายความน่าจะเป็นของคนสูบบุหรี่แล้วจะเป็นโรคมะเร็งปอด **P(มะเร็งปอด|สูบบุหรี่)** หรือความน่าจะเป็นที่จะเกิดอุบัติเหตุทางรถยนต์ของคนคุยโทรศัพท์ระหว่างขับรถ **P(อุบัติเหตุ|คุยโทรศัพท์ระหว่างขับรถ)** เป็นต้น



การหาตำแหน่งแบบควอร์ไทล์ (Quartile)


การหาตำแหน่งแบบควอร์ไทล์ (Quartile) เป็นการเรียงข้อมูลจากน้อยไปมากก่อน แล้วแบ่งข้อมูลออกเป็น 4 ส่วน แต่ละส่วนมีจำนวนข้อมูลเท่ากันหมด เพื่อให้ผู้อ่านเห็นภาพชัดเจนยิ่งขึ้น ผู้เขียนจำลองด้วยเส้นจำนวนจริง ดังรูปที่ 12-1



รูปที่ 12-1 แสดงเส้นจำนวนแบ่งข้อมูลออกเป็น 4 ส่วนเท่าๆ กัน



การหาตำแหน่งของข้อมูล



รูปที่ 12-1 แสดงเส้นจำนวนแบ่งข้อมูลออกเป็น 4 ส่วนเท่าๆ กัน

จากรูปที่ 12-1 การแบ่งข้อมูลออกเป็น 4 ส่วนแบบควอร์ไทล์ ส่งผลให้เกิดจุดแบ่ง 3 จุด เรียกว่า Q_1 , Q_2 และ Q_3 (อ่านว่า ควอร์ไทล์ที่...) โดยที่ตำแหน่ง Q_2 คือ จุดกึ่งกลาง

ความหมายของแต่ละควอร์ไทล์ก็คือ

- Q_1 แปลว่า มีข้อมูลจำนวน 1 ส่วน (25%) ที่มีค่าน้อยกว่า และมีข้อมูลจำนวน 3 ส่วน (75%) ที่มีค่ามากกว่า
- Q_3 แปลว่า มีข้อมูลจำนวน 3 ส่วน (75%) ที่มีค่าน้อยกว่า และมีข้อมูลจำนวน 1 ส่วน (25%) ที่มีค่ามากกว่า

มีข้อมูลตัวเลข 7 ตัว ประกอบด้วย 3, 4, 5, 6, 7, 8 และ 9 ผู้เขียนกำหนดจำนวนข้อมูลลงตัว เพื่อให้ผู้อ่านมองง่ายขึ้น ต้องการแบ่งข้อมูลชุดนี้ออกเป็น 4 ส่วนแบบควอร์ไทล์ กล่าวคือ

ข้อมูล	3	4	5	6	7	8	9
ตำแหน่ง		Q_1		Q_2		Q_3	

จากตารางข้างต้น ความหมายคือ

- **ตำแหน่ง Q_1** ตรงกับข้อมูล 4 มีข้อมูลที่มีค่าน้อยกว่า 1 ตัว และมีข้อมูลที่มีค่ามากกว่า 5 ตัว
- **ตำแหน่ง Q_2** ตรงกับข้อมูล 6 มีข้อมูลที่มีค่าน้อยกว่า 3 ตัว และมีข้อมูลที่มีค่ามากกว่า 3 ตัว
- **ตำแหน่ง Q_3** ตรงกับข้อมูล 8 มีข้อมูลที่มีค่าน้อยกว่า 5 ตัว และมีข้อมูลที่มีค่ามากกว่า 1 ตัว



การหาตำแหน่งของข้อมูล

ในกรณีนี้ เรามีข้อมูลตัวเลขเพียง 7 ตัว จำนวนข้อมูลน้อยและเป็นจำนวนลงตัว สามารถแบ่งด้วยตาเปล่าได้เลย แต่ในทางสถิติวิธีการคำนวณควอร์ไทล์มี 3 ขั้นตอน คือ

1. เรียงลำดับข้อมูลจากค่าน้อยไปสู่ค่ามาก เพื่อจัดเรียงข้อมูล
2. คำนวณหาตำแหน่ง ให้ผู้อ่านคำนวณหาตำแหน่งก่อน โดยใช้สูตร

$$Q_r = \frac{r(n + 1)}{4}$$

โดยที่ r หมายถึง ควอร์ไทล์ที่

n คือ จำนวนข้อมูล

3. เชื่อมโยงตำแหน่งกับข้อมูล เมื่อผู้อ่านได้ตำแหน่งมาจากข้อที่ 2 แล้วให้นำไปตรวจสอบว่าตรงกับข้อมูลตัวใด



การหาตำแหน่งของข้อมูล

ผู้เขียนใช้ข้อมูลชุดเดิมคือ 3, 4, 5, 6, 7, 8 และ 9 เราจะมาคำนวณหา Q_1 , Q_2 และ Q_3 ประกอบด้วย

1. เรียงลำดับจากค่าน้อยไปสู่ค่ามาก ข้อมูลชุดนี้เรียงลำดับอยู่แล้ว

2. คำนวณหาตำแหน่ง จากสูตร $Q_r = \frac{r(n+1)}{4}$

- ตำแหน่ง Q_1 คือ $\frac{1(7+1)}{4} = \frac{8}{4} = 2$

- ตำแหน่ง Q_2 คือ $\frac{2(7+1)}{4} = \frac{16}{4} = 4$

- ตำแหน่ง Q_3 คือ $\frac{3(7+1)}{4} = \frac{24}{4} = 6$

3. เชื่อมโยงตำแหน่งกับข้อมูล

- ข้อมูลที่ Q_1 ข้อมูลที่อยู่ในตำแหน่งที่ 2 คือ ข้อมูล 4

- ข้อมูลที่ Q_2 ข้อมูลที่อยู่ในตำแหน่งที่ 4 คือ ข้อมูล 6

- ข้อมูลที่ Q_3 ข้อมูลที่อยู่ในตำแหน่งที่ 6 คือ ข้อมูล 8



การหาตำแหน่งของข้อมูล

ตัวอย่างที่ 12-1 การหาตำแหน่งควอร์ไทล์ด้วยฟังก์ชัน `quantile()` ของ `statistics`
การหาตำแหน่งควอร์ไทล์ของข้อมูลด้วยฟังก์ชัน `quantile()` ใช้วิธีการกำหนดค่าตั้งแต่ 0.00 ถึง 1.00 กล่าวคือ

- ค่า Q_1 มีค่าเท่ากับ 0.25
- ค่า Q_2 มีค่าเท่ากับ 0.50
- ค่า Q_3 มีค่าเท่ากับ 0.75

ผู้เขียนนำข้อมูลชุดเดิมมาหาค่าควอร์ไทล์ ดังโค้ดต่อไปนี้

โค้ดไพธอนที่ 12-1 การหาตำแหน่งควอร์ไทล์ด้วยฟังก์ชัน `quantile()` ของ `statistics`
(UsingQuantile.py)

```
import numpy as np
from statistics import quantiles

data = [15, 22, 17, 14, 25, 16, 18, 18]
arr = np.array(data)


np.quantile(arr, (0.25, 0.50, 0.75))
print(quantiles(arr))
```



การหาตำแหน่งของข้อมูล

การหาตำแหน่งแบบเดไซล์ (Decile)

การหาตำแหน่งแบบเดไซล์ (Decile) เป็นการแบ่งข้อมูลที่มีอยู่ออกเป็น 10 ส่วนเท่าๆ กัน ส่งผลให้มีจุดแบ่ง 9 จุด คือ D_1 ถึง D_9 โดยที่ตำแหน่ง D_5 คือ ตำแหน่งกึ่งกลาง ดังรูปที่ 12-3



รูปที่ 12-3 แสดงเส้นจำนวนแบ่งข้อมูลออกเป็น 10 ส่วนเท่าๆ กัน

ความหมายของตำแหน่งเดไซล์คือ

- D_3 หมายถึง มีข้อมูล 3 ส่วนที่มีค่าน้อยกว่า และมีข้อมูล 7 ส่วนที่มีค่ามากกว่า
- D_9 หมายถึง มีข้อมูล 9 ส่วนที่มีค่าน้อยกว่า และมีข้อมูล 1 ส่วนที่มีค่ามากกว่า

วิธีการคำนวณเดไซล์ มี 3 ขั้นตอนคือ

1. เรียงลำดับข้อมูลจากค่าน้อยไปสู่ค่ามาก เพื่อจัดเรียงข้อมูล
2. คำนวณหาตำแหน่ง ให้ผู้อ่านคำนวณหาตำแหน่งก่อน โดยใช้สูตร

$$D_r = \frac{r(n + 1)}{10}$$

โดยที่ r หมายถึง เดไซล์ที่

n คือ จำนวนข้อมูล



การหาตำแหน่งของข้อมูล

3. **เชื่อมโยงตำแหน่งกับข้อมูล** เมื่อผู้อ่านได้ตำแหน่งมาจากข้อที่ 2 แล้วให้นำไปตรวจสอบว่าตรงกับข้อมูลตัวใด

เช่น มีข้อมูลประกอบด้วย 27, 36, 39, 28, 30, 25, 21, 29, 31 และ 33 ต้องการหาค่า D_4 และ D_7 ดังขั้นตอนต่อไปนี้

1. **เรียงลำดับข้อมูลจากค่าน้อยไปสู่ค่ามาก** มีข้อมูล 10 ตัว คือ 21, 25, 27, 28, 29, 30, 31, 33, 36 และ 39

2. **คำนวณหาตำแหน่ง** จากสูตร $D_r = \frac{r(n+1)}{10}$

- ตำแหน่ง D_4 คือ $\frac{4(10+1)}{10} = \frac{44}{10} = 4.4$

- ตำแหน่ง D_7 คือ $\frac{7(10+1)}{10} = \frac{77}{10} = 7.7$


3. **เชื่อมโยงตำแหน่งกับข้อมูล** เป็นตำแหน่งข้อมูลที่ไม่ลงตัว มีค่าเป็นเศษส่วน มีความหมายว่า

- ข้อมูลที่ D_4** อยู่ที่ตำแหน่ง 4.4 มีค่าอยู่ระหว่างข้อมูลตัวที่ 4 (28) กับข้อมูลตัวที่ 5 (29) ตำแหน่งที่ 4 กับตำแหน่งที่ 5 ห่างกัน 1 ช่อง มีข้อมูลห่างกันคือ 1 (เกิดจาก $29 - 28$) ตำแหน่งที่ 4 กับตำแหน่งที่ 5 ห่างกัน 0.4 ช่อง มีข้อมูลห่างกันคือ $\frac{(0.4 \times 1)}{1} = 0.4$ นำข้อมูลในตำแหน่งที่ 4 คือ 28 บวกด้วยค่าที่เลยไปอีก 0.4 กลายเป็น 28.4 คือ ค่า D_4
- ข้อมูลที่ D_7** อยู่ที่ตำแหน่ง 7.7 มีค่าอยู่ระหว่างข้อมูลตัวที่ 7 (31) กับข้อมูลตัวที่ 8 (33) ตำแหน่งที่ 7 กับตำแหน่งที่ 8 ห่างกัน 1 ช่อง มีข้อมูลห่างกันคือ 2 (เกิดจาก $33 - 31$) ตำแหน่งที่ 7 กับตำแหน่งที่ 8 ห่างกัน 0.7 ช่อง มีข้อมูลห่างกันคือ $\frac{(0.7 \times 2)}{1} = 1.4$ นำข้อมูลในตำแหน่งที่ 7 คือ 31 บวกด้วยค่าที่เลยไปอีก 1.4 กลายเป็น 32.4 คือ ค่า D_7



การหาตำแหน่งแบบเปอร์เซ็นต์ไทล์ (Percentile)


การหาตำแหน่งแบบเปอร์เซ็นต์ไทล์ (Percentile) คือ การแบ่งข้อมูลออกเป็น 100 ส่วน ส่งผลให้มีจุดแบ่ง 99 จุด คือ P_1 ถึง P_{99} โดยมีตำแหน่ง P_{50} คือ จุดกึ่งกลางของข้อมูล



รูปที่ 12-5 แสดงเส้นจำนวนแบ่งข้อมูลออกเป็น 100 ส่วนเท่าๆ กัน



การหาตำแหน่งของข้อมูล



รูปที่ 12-5 แสดงเส้นจำนวนแบ่งข้อมูลออกเป็น 100 ส่วนเท่าๆ กัน

ความหมายของตำแหน่งเปอร์เซ็นต์ไทล์คือ

- P_{31} หมายถึง มีข้อมูล 31 ส่วนที่มีค่าน้อยกว่า และมีข้อมูล 69 ส่วนที่มีค่ามากกว่า
- P_{95} หมายถึง มีข้อมูล 95 ส่วนที่มีค่าน้อยกว่า และมีข้อมูล 5 ส่วนที่มีค่ามากกว่า

วิธีการคำนวณเปอร์เซ็นต์ไทล์ มี 3 ขั้นตอน คือ

1. เรียงลำดับข้อมูลจากค่าน้อยไปสู่ค่ามาก เพื่อจัดเรียงข้อมูล
2. คำนวณหาตำแหน่ง ให้ผู้อ่านคำนวณหาตำแหน่งก่อน โดยใช้สูตร

$$P_r = \frac{r(n+1)}{100}$$

โดยที่ r หมายถึง เปอร์เซ็นต์ไทล์ที่

n คือ จำนวนข้อมูล

3. เชื่อมโยงตำแหน่งกับข้อมูล เมื่อผู้อ่านได้ตำแหน่งมาจากข้อที่ 2 แล้วให้นำไปตรวจสอบว่าตรงกับข้อมูลตัวใด

เช่น มีข้อมูลจำนวน 10 ตัว คือ 9, 15, 17, 16, 19, 23, 20, 20, 21 และ 11 ให้หา P_{21} และ P_{83} มีขั้นตอนดังนี้

1. เรียงลำดับข้อมูลจากค่าน้อยไปสู่ค่ามาก มีข้อมูล 10 ตัว คือ 9, 11, 15, 16, 17, 19, 20, 20, 21 และ 23

2. คำนวณหาตำแหน่ง จากสูตร $P_r = \frac{r(n+1)}{100}$

- ตำแหน่ง P_{21} คือ $\frac{21(10+1)}{100} = \frac{231}{100} = 2.31$

- ตำแหน่ง P_{83} คือ $\frac{83(10+1)}{100} = \frac{913}{100} = 9.13$



การหาตำแหน่งของข้อมูล

ตัวอย่างที่ 12-3 การหาค่าแบบเปอร์เซ็นต์ไทล์ (Percentile) ใน NumPy

มีข้อมูลเก็บอยู่ในตัวแปร data อยู่ 10 ตัว ต้องการหาค่า P_{21} และ P_{83} ดังโค้ดต่อไปนี้

โค้ดไพธอนที่ 12-3 การหาค่าแบบเปอร์เซ็นต์ไทล์ (Percentile) ใน NumPy (UsingQuantile.py)

```
import numpy as np
from statistics import quantiles

data = [9, 15, 17, 16, 19, 23, 20, 20, 21, 11]
arr = np.array(data)


i = 1
for q in quantiles(data, n=100):
    print('P' + str(i) + ' : ', q)
    i = i + 1
```

PROBLEMS OUTPUT DEBUG CONSOLE

```
P1 : 7.22
P2 : 7.44
P3 : 7.66
P4 : 7.88
P5 : 8.1
P6 : 8.32
P7 : 8.54
P8 : 8.76
P9 : 8.98
P10 : 9.2
P11 : 9.42
P12 : 9.64
P13 : 9.86
```

PROBLEMS OUTPUT DEBUG CONSOLE

```
P74 : 20.14
P75 : 20.25
P76 : 20.36
P77 : 20.47
P78 : 20.58
P79 : 20.69
P80 : 20.8
P81 : 20.91
P82 : 21.04
P83 : 21.26
P84 : 21.48
P85 : 21.7
P86 : 21.92
```



Learn Python basic programming

What we learn ?



Datatype

Built-in
function

Lists

OOP

Variable

Methods

Dictionary

Package

Operator

String

Condition



Etc...

Input Data

Number

Loop

"Python Is Engineering, Not Art"



Create and Activate Python Virtual Environment (VENV)

Create Virtualenv



```
python -m venv name
```

example

```
D:\BasicPythonEGAT>python -m venv env
```

```
\Include  
\Lib  
\Scripts  
pyvenv.cfg
```



```
$ python3 -m venv name
```

example

```
$ python3 -m venv env
```

```
/bin  
/Include  
/Lib  
pyvenv.cfg
```

Activate virtual environment




```
env\Scripts\activate
```

```
Command Prompt
D:\BasicPythonEGAT>env\Scripts\activate
(env) D:\BasicPythonEGAT>
```



```
$ source env/bin/activate
```

```
(env) samit@MacbookM1Pro pythonbeginner % pip list
Package      Version
-----
pip           22.1.2
setuptools    49.2.1
(env) samit@MacbookM1Pro pythonbeginner % python hello.py
Hello Python
(env) samit@MacbookM1Pro pythonbeginner %
```



Jupyter Notebook คือ อะไร

Jupyter Notebook คือ เครื่องมือที่ใช้เขียน Code ในการที่เราจะสร้าง Machine learning model เป็นเครื่องมือที่นิยมมากในกลุ่มคนที่ทำงานด้าน Data Science เหมาะกับการทำงานที่เกี่ยวข้องกับการจัดการข้อมูลเป็นจำนวนมากแล้วยังต้องรายงานงานวิจัยที่ตนเองได้ทำขึ้นมา

ตัว Jupyter Notebook ก็ได้ออกแบบมาตรงตามจุดประสงค์การใช้งานไม่ว่าจะเป็น การเรียกใช้งาน library พร้อมทั้งเขียน code และดูผลได้เลย Jupyter Notebook นั้นถูกออกแบบมาให้ทำงานและอ่านได้ง่ายกว่าการที่เรา text editor รวมไปถึงเรายังสามารถที่จะพิมพ์ตัวหนังสือภาษาไทยลงไปได้เลย เหมือนเราพิมพ์รายงานใน Microsoft Word ได้เลยทีเดียว


ติดตั้ง Jupyter Notebook

```
pip install jupyter
```

เรียกใช้งาน Jupyter Notebook

```
jupyter notebook
```


ระบบจะเปิด Web Browser มายัง <http://localhost:8888>



จากนั้น คลิกที่ปุ่ม New > Python3

The screenshot shows the JupyterLab web interface in a browser. The address bar displays 'localhost:8888/tree/Developments/python/keras'. The Jupyter logo and 'Quit'/'Logout' buttons are at the top. Below the navigation tabs (Files, Running, Clusters), there is a prompt 'Select items to perform actions on them.' and a file browser showing the directory structure: / Developments / python / keras. The file list includes notebooks like 'basic01.ipynb', 'MobileNet01.ipynb', and 'nlp.ipynb', as well as image files '1.png' through '4.png', and CSV files 'pima-indians-diabetes.data.csv' and 'pima-indians-diabetes.names'. In the top right of the file browser, the 'New' button is highlighted with a red circle labeled '1'. A dropdown menu is open, showing 'Python 3' as the selected option, which is also highlighted with a red box and a red circle labeled '2'. Other options in the menu include 'Text File', 'Folder', and 'Terminal'. A tooltip next to the 'Python 3' option reads 'Create a new notebook with Python 3'.

จากนั้น เราก็จะสามารถใช้คำสั่ง Python ทัว ๆ ไปได้



← → ↻

localhost:8888/tree/pythonWithDatabase

jupyter

Quit

Logout

Files

Running

Clusters

Select items to perform actions on them.

Upload

New

0

/ pythonWithDatabase

Name

Last Modified

File size

..

seconds ago

☐

9.1.ipynb

16 minutes ago

949 B

☐

9.10.ipynb

2 years ago

2.14 kB

☐

9.11.ipynb

2 years ago

2.09 kB

☐

9.12.ipynb

2 years ago

2.45 kB

☐

9.13.ipynb

2 years ago

2.79 kB

☐

9.14.ipynb

2 years ago

1.75 kB

☐

9.15.ipynb

2 years ago

1.66 kB

☐

9.16.ipynb

2 years ago

1.82 kB

☐

9.17.ipynb

2 years ago

1.65 kB

☐

9.2.ipynb

2 years ago

2.7 kB

☐

9.3.ipynb

2 years ago

4.25 kB

☐

9.4.ipynb

2 years ago

3.01 kB

☐

9.5.ipynb

2 years ago

2.05 kB

☐

9.6.ipynb

2 years ago

2 kB

☐

9.7.ipynb

2 years ago

2.02 kB

☐

9.8.ipynb

2 years ago

1.84 kB

☐

9.9.ipynb

2 years ago


2.49 kB

https://beyourcyber.com/2017/newbie-python-with-jupyter-notebook/


การใช้งาน Jupyter notebook ใน VS Code



การใช้งาน Jupyter notebook ใน VS Code



การใช้งาน Jupyter notebook ใน VS Code




The screenshot displays the Visual Studio Code interface with a Jupyter notebook open. The notebook editor shows a single code cell with the following Python code:

```
print("Hello Notebook")
```

Below the code editor, the Jupyter terminal is active, showing the output of the code execution. The terminal output includes progress bars for downloading various Python packages and their versions:

```
Collecting python-dateutil>=2.1
  Downloading python_dateutil-2.8.2-py2.py3-none-any.whl (247 kB)
  247 kB 6.4 MB/s
Collecting jupyter-core>=4.6.0
  Downloading jupyter_core-4.9.1-py3-none-any.whl (86 kB)
  86 kB ...
Collecting pywin32>=1.0
  Downloading pywin32-303-cp310-cp310-win_amd64.whl (9.2 MB)
  9.2 MB 6.4 MB/s
Collecting wcwidth
  Downloading wcwidth-0.2.5-py2.py3-none-any.whl (30 kB)
Collecting six>=1.5
  Downloading six-1.16.0-py2.py3-none-any.whl (11 kB)
Using legacy 'setup.py install' for tornado, since package 'wheel' is not installed.
Installing collected packages: wcwidth, traitlets, six, pywin32, parso, tornado, pyzmq, python-dateutil, pygments, prompt-toolkit, pickleshare, nest-asyncio, matplotlib-inline, jupyter-core, jedi, entrypoints, decorator, colorama, backcall, jupyter-client, ipython, debugpy, ipykernel
Running setup.py install for tornado ... done
Successfully installed backcall-0.2.0 colorama-0.4.4 debugpy-1.5.1 decorator-5.1.0 entrypoints-0.3 ipykernel-6.6.0 ipython-7.30.1 jedi-0.18.1 jupyter-client-7.1.0 jupyter-core-4.9.1 matplotlib-inline-0.1.3 nest-asyncio-1.5.4 parso-0.8.3 pickleshare-0.7.5 prompt-toolkit-3.0.24 pygments-2.10.0 python-dateutil-2.8.2 pywin32-303 pyzmq-22.3.0 six-1.16.0 tornado-6.1 traitlets-5.1.1 wcwidth-0.2.5
WARNING: You are using pip version 21.2.3; however, version 21.3.1 is available.
You should consider upgrading via the 'python -m pip install --upgrade pip' command.
```


การใช้งาน Jupyter notebook ใน VS Code



A screenshot of the VS Code terminal window showing the output of a command that lists installed Jupyter dependencies. The terminal has tabs for PROBLEMS, OUTPUT, DEBUG CONSOLE, and TERMINAL. The output is a list of package names and their versions, with 'matplotlib' highlighted in a red bar. A mouse cursor is pointing at the version '21.3' for the 'packaging' package.

fonttools	4.28.5
ipykernel	6.6.0
ipython	7.30.1
jedi	0.18.1
jupyter-client	7.1.0
jupyter-core	4.9.1
kiwisolver	1.3.2
matplotlib	3.5.1
matplotlib-inline	0.1.3
nest-asyncio	1.5.4
numpy	1.21.5
packaging	21.3
parso	0.8.3
pickleshare	0.7.5
Pillow	8.4.0
pip	21.2.3
prompt-toolkit	3.0.24
pycodestyle	2.8.0
Pygments	2.10.0
pyparsing	3.0.6
python-dateutil	2.8.2
pywin32	303
pyzmq	22.3.0
setuptools	57.4.0
six	1.16.0
toml	0.10.2
tornado	6.1
traitlets	5.1.1
wcwidth	0.2.5

การใช้งาน Jupyter notebook ใน VS Code




The screenshot displays a Jupyter notebook interface within the VS Code editor. The notebook is titled 'demo1.ipynb' and contains four code cells, each with a status bar indicating successful execution and timing.

- Cell 1:** Contains the code `print("Hello Notebook")`. The output is 'Hello Notebook'.
- Cell 2:** Contains the code `2**3`. The output is '8'.
- Cell 3:** Contains the code `import math` and `math.pi`. The output is '3.141592653589793'.
- Cell 4:** Contains the code `import matplotlib.pyplot as plt` and `%matplotlib inline`. The output is a line plot showing a series of points connected by lines. The x-axis ranges from 0 to 10, and the y-axis ranges from 3 to 10. The plot shows a line starting at (0, 3), rising to (4, 4), then to (6, 10), and finally to (8, 7).

The interface includes a top toolbar with options like 'Code', 'Markdown', 'Run All', 'Clear Outputs of All Cells', 'Restart', 'Interrupt', 'Variables', and 'Outline'. The bottom right corner of the notebook shows the Python version 'Python 3.10.0 64-bit'.


การใช้งาน Jupyter notebook ใน VS Code



A screenshot of the VS Code terminal window showing the output of a command that lists installed Jupyter dependencies. The terminal has tabs for PROBLEMS, OUTPUT, DEBUG CONSOLE, and TERMINAL. The output is a list of package names and their versions, with 'pandas' highlighted in a purple bar. A cursor is visible on the right side of the terminal.

entrypoints	0.3
fonttools	4.28.5
ipykernel	6.6.0
ipython	7.30.1
jedi	0.18.1
jupyter-client	7.1.0
jupyter-core	4.9.1
kiwisolver	1.3.2
matplotlib	3.5.1
matplotlib-inline	0.1.3
nest-asyncio	1.5.4
numpy	1.21.5
packaging	21.3
pandas	1.3.5
parso	0.8.3
pickleshare	0.7.5
Pillow	8.4.0
pip	21.2.3
prompt-toolkit	3.0.24
pycodestyle	2.8.0
Pygments	2.10.0
pyparsing	3.0.6
python-dateutil	2.8.2
pytz	2021.3
pywin32	303
pyzmq	22.3.0
setuptools	57.4.0
six	1.16.0
toml	0.10.2
tornado	6.1

การใช้งาน Jupyter notebook ใน VS Code



demo1.ipynb

+ Code + Markdown Run All Clear Outputs of All Cells Restart Interrupt Variables Outline ... Python 3.10.0 64-bit

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

p = np.linspace(0,20,100)
plt.plot(p, np.sin(15*p))
plt.show()
```


[] Python

```
df = pd.read_csv('https://raw.githubusercontent.com/prasertcbs/basic-dataset/master/iris.csv')
df.sample(10)
```

[49] ✓ 0.5s Python

	sepal_length	sepal_width	petal_length	petal_width	species
75	6.6	3.0	4.4	1.4	versicolor
89	5.5	2.5	4.0	1.3	versicolor
58	6.6	2.9	4.6	1.3	versicolor
68	6.2	2.2	4.5	1.5	versicolor
38	4.4	3.0	1.3	0.2	setosa
0	5.1	3.5	1.4	0.2	setosa
27	5.2	3.5	1.5	0.2	setosa
134	6.1	2.6	5.6	1.4	virginica
73	6.1	2.8	4.7	1.2	versicolor
17	5.1	3.5	1.4	0.3	setosa

<https://raw.githubusercontent.com/prasertcbs/basic-dataset/master/iris.csv>



Module 3

สร้างและจัดการอาร์เรย์ข้อมูล ด้วยไลบรารี Numpy

- ติดตั้งและเรียกใช้งานไลบรารี Numpy
- การสร้างอาร์เรย์
- การสร้างอาร์เรย์ด้วยการสุ่มตัวเลข
- การเลือกสมาชิกในอาร์เรย์
- การดูรายละเอียดของ Matrix
- การหาค่าทางสถิติของอาร์เรย์
- การปรับเปลี่ยนอาร์เรย์
- การคำนวณเวกเตอร์
- การคำนวณ Matrix

ติดตั้งและเรียกใช้งานไลบรารี Numpy

NumPy (มาจากคำว่า Numerical Python) เป็นไลบรารีสำหรับการจัดการข้อมูลประเภทตัวเลข โดย NumPy จะจัดการข้อมูลในรูปแบบอาร์เรย์ (Array) หรือเรียกว่า Array-Oriented เป็นหลัก ถึงแม้จะมีลักษณะคล้ายกับลิสต์(List) ในภาษา Python แต่อาร์เรย์ของ NumPy จะทำงานได้เร็วกว่าลิสต์ นอกจากนี้ NumPy ยังประกอบด้วยฟังก์ชันต่าง ๆ สำหรับการประมวลผลทางคณิตศาสตร์ให้เลือกใช้มากมาย ซึ่งช่วยลดความจำเป็นการเขียนโค้ดPython ลงไปได้

ติดตั้ง Numpy ผ่าน pip

```
pip install numpy
```

การเรียกใช้งาน Numpy

```
import numpy as np
```

การสร้างอาเรย์

สเกลาร์ (Scalar) เป็นปริมาณทางกายภาพที่มีเฉพาะขนาดและเป็นอาเรย์ 0 มิติ เช่น

```
import numpy as np
a = np.array(12)

print(a)
```

เวกเตอร์ (Vector) เป็นการสร้างอาเรย์ 1 มิติ มี 2 รูปแบบด้วยกัน คือ เวกเตอร์แนวนอน ซึ่งมี 1 แถว n คอลัมน์ และเวกเตอร์แนวตั้ง ซึ่งมี n แถว 1 คอลัมน์

```
import numpy as np
row = np.array([1, 3, 5, 7])
col = np.array([[2], [4], [6], [8]])
print(row)
print(col)
```

การสร้างอาเรย์

เมทริกซ์ (Matrix) เป็นการสร้างอาเรย์ 2 มิติ ซึ่งนิยมนำไปประยุกต์ใช้ในการสร้างตารางข้อมูล ตัวอย่างเช่น สร้างอาเรย์ 2 แถว 3 คอลัมน์

```
import numpy as np
mat = np.array([[11, 12, 13], [14, 15, 16]]) # สร้างอาเรย์ 2 มิติ

print(mat)
```

```
In [7]: 1 mat = np.array([[11, 12, 13], [14, 15, 16]]) # สร้างอาเรย์ 2 มิติ
        2
        3 print(mat)

[[11 12 13]
 [14 15 16]]
```

การสร้างอาร์เรย์ด้วยการสุ่มตัวเลข

เราสามารถสร้าง Vector หรือ Matrix ด้วยการสุ่มค่าตัวเลขขึ้นมา โดยใช้ฟังก์ชัน `random.random()` และ `random.randint()`

`random.random([size])` เป็นการสุ่มตัวเลขทศนิยมระหว่าง 0.0 ถึง 1.0 ตามขนาด size ที่กำหนด

การสร้างอาร์เรย์ด้วยการสุ่มตัวเลข

```
In [29]: 1 r1 = np.random.random(4) # สุ่ม vector 4 จำนวน  
2 r2 = np.random.random([4,2]) # สุ่ม matrix 4x2  
3 print(r1)  
4 print(r2)
```

```
[0.74388745 0.785801  0.99175689 0.90470835]  
[[0.66695946 0.9118165 ]  
 [0.84448921 0.6751839 ]  
 [0.96119701 0.39534498]  
 [0.30674406 0.11066718]]
```

การสร้างอาเรย์ด้วยการสุ่มตัวเลข

เราสามารถสร้าง Vector หรือ Matrix ด้วยการสุ่มค่าตัวเลขขึ้นมา โดยใช้ฟังก์ชัน `random.random()` และ `random.randint()`

`random.randint(low, high=None, size=None, dtype=int)` เป็นการสุ่มตัวเลขจำนวนเต็ม โดยให้ low ค่าต่ำสุด, ค่าสูงสุด และ size ที่ต้องการ

```
In [31]: 1 r3 = np.random.randint(0, 11, 4) # สุ่ม vector 0-10 มา 4 จำนวน  
2 r4 = np.random.randint(0, 11, [2, 3]) # สุ่ม maxtrix 0-10 ขนาด 2x3  
3  
4 print(r3)  
5 print(r4)
```

```
[5 7 5 8]  
[[ 9 10  4]  
 [ 3  6  7]]
```

สร้างอาร์เรย์โดยใช้ฟังก์ชันอื่น ๆ ของ Numpy

zeros(size)	สร้างอาร์เรย์โดยให้สมาชิกทุกตัวมีค่าเริ่มแรกเป็น 0 ทั้งหมด
ones(size)	สร้างอาร์เรย์โดยให้สมาชิกทุกตัวมีค่าเริ่มแรกเป็น 1 ทั้งหมด
full(size, value)	สร้างอาร์เรย์โดยกำหนดจำนวนสมาชิกและค่าเริ่มต้น (value) ตามที่ระบุ
arange(start, stop, step)	กำหนดช่วงข้อมูลเช่นเดียวกับ range() ของ Python
linspace(begin, end, size)	มักใช้ในเงื่อนไขที่ว่า ต้องการชุดข้อมูลระหว่าง $x - y$ ทั้งหมด n จำนวน ทั้งนี้เราต้องระบุอาร์กิวเมนต์เป็นค่าแรก ค่าสุดท้าย และจำนวนที่ต้องการ โดยช่วงข้อมูลระหว่างค่าแรกและค่าสุดท้าย จะถูกแบ่งให้มีระยะห่างเท่า ๆ กัน เพื่อให้ได้จำนวนตามที่ต้องการ
random.randint(low, high, size)	เมื่อต้องการเลขจำนวนเต็มที่อยู่ระหว่างค่า low และ high - 1 โดย size คือจำนวนที่ต้องการ
random.uniform(low, high, size)	เมื่อต้องการเลขทศนิยมที่อยู่ระหว่างค่า low และ high - 1 โดย size คือจำนวนที่ต้องการ
random.rand(size)	เมื่อต้องการอาร์เรย์เป็นเลขทศนิยมระหว่าง 0 - 1 และมีจำนวนสมาชิกตามค่า size ที่ระบุ

สร้างอาเรย์โดยใช้ฟังก์ชันอื่น ๆ ของ Numpy

สร้างอาเรย์โดยใช้ฟังก์ชันอื่น ๆ ของ Numpy

In [48]:

```
1 a = np.zeros(5)      #[0 0 0 0 0]
2 b = np.ones(5)       #[1 1 1 1 1]
3 c = np.full(5, 8)    #[8 8 8 8 8]
4 d = np.arange(1, 6)  #[1 2 3 4 5]
5 e = np.arange(1, 10, 2) #[1 3 5 7 9]
6 f = np.linspace(1, 10, 4) #[1 4 7 10]
7 g = np.linspace(1, 10, 6) #[1 2.8 4.6 6.4 8.2 10]
8 h = np.random.uniform(1, 101, 10) #สุ่มเลขระหว่าง 1-100 ทั้งหมด 10 จำนวน
9 i = np.random.rand(10)
```

```
10 print(a)
11 print(b)
12 print(c)
13 print(d)
14 print(e)
15 print(f)
16 print(g)
17 print(h)
18 print(i)
```

```
[0. 0. 0. 0. 0.]
[1. 1. 1. 1. 1.]
[8 8 8 8 8]
[1 2 3 4 5]
[1 3 5 7 9]
[ 1.  4.  7. 10.]
[ 1.  2.8  4.6  6.4  8.2 10. ]
[97.92373443 39.82554546 96.25046316 59.03946524 80.61193107 14.97039918
 62.0967763  55.05840361 81.4930271  25.59836502]
[0.42861057 0.92527966 0.64256764 0.36972352 0.45751929 0.64275691
 0.15388112 0.02102778 0.12830145 0.2865833 ]
```

การเข้าถึงและเลือกสมาชิกในอาเรย์

การเลือกสมาชิกเวกเตอร์แบบแถว

```
1 vrow = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10])
2 
3 print(vrow[3]) # เลือกสมาชิกเพียง 1 ตัว คือตัวที่ 4 นับจากข้างหน้า
4 print(vrow[-3]) # เลือกสมาชิกตัวที่ 3 นับจากข้างหลัง
```

[67]

Python

```
... 4
     8
```

การเลือกช่วงของสมาชิก

```
1 vrow1 = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10])
2 
3 print(vrow1[2:7]) # เลือกตั้งแต่ตัวที่ 3 ถึง ตัวที่ 6
4 print(vrow1[:4]) # เลือกตั้งแต่ตัวแรก จนถึงตัวที่ 4
5 print(vrow1[7:]) # เลือกจากตัวที่ 7 ถึงตัวสุดท้าย
```

[70]

Python

```
... [3 4 5 6 7]
     [1 2 3 4]
     [ 8  9 10]
```

การเข้าถึงและเลือกสมาชิกในอาเรย์

การเลือกสมาชิกในเมทริกซ์ (matrix)

เลือกสมาชิกหนึ่งตัวจาก matrix

```
1 mat1 = np.array([[1, 2, 3, 4], [5, 6, 7, 8], [9, 10, 11, 12]])
2 
3 print(mat1)
4 print(mat1[1, 2])
```

[73]

Python

```
... [[ 1  2  3  4]
      [ 5  6  7  8]
      [ 9 10 11 12]]
7
```

เลือกสมาชิกในช่วงของแถว matrix

```
1 mat2 = np.array([[1, 2, 3, 4], [5, 6, 7, 8], [9, 10, 11, 12]])
2 
3 print(mat2[:2,:]) # เลือกสมาชิกแถวที่ 1-2
4 print(mat2[1:3, 0:3]) # เลือกแถวที่ 1-3 และคอลัมน์ที่ 0-3
```

[78]

Python

```
... [[1 2 3 4]
      [5 6 7 8]]
[[ 5  6  7]
 [ 9 10 11]]
```

การเข้าถึงและเลือกสมาชิกในอาเรย์

การดูรายละเอียดของเมทริกซ์ (matrix) shape, size, dimension

```
1 # การดูรูปร่าง (shape) ของ matrix
2 mt = np.array([[1, 2, 3, 4], [5, 6, 7, 8], [9, 10, 11, 12]])
3
4 print(mt.shape) # shape ของ matrix
5
6 # การดูขนาด (size) ของ matrix
7 print(mt.size) # คำนวณออกมาเป็นจำนวนสมาชิกทั้งหมด
8
9 # การดู dimension ของ matrix
10 print(mt.ndim) # คำนวณออกมาเป็นจำนวน มิติของอาเรย์
11
```

[82]

Python

```
... (3, 4)
12
2
```

การหาค่าทางสถิติของอาเรย์

```
1 mtstat = np.array([[1, 2, 3, 4], [5, 6, 7, 8], [9, 10, 11, 12]])
2
3 print(np.max(mtstat)) # หาค่าสูงสุด
4 print(np.min(mtstat)) # หาค่าต่ำสุด
5 print(np.mean(mtstat)) # หาค่าเฉลี่ย
6 print(np.var(mtstat)) # หาค่าความแปรปรวน
7 print(np.std(mtstat)) # หาค่าเบี่ยงเบนมาตรฐาน
```

[86]

Python

```
... 12
1
6.5
11.916666666666666
3.452052529534663
```

การเข้าถึงและเลือกสมาชิกในอาเรย์

การปรับเปลี่ยนอาเรย์

```
1 mtadj = np.array([[1, 2, 3, 4], [5, 6, 7, 8], [9, 10, 11, 12]])
2
3 print(mtadj)
4
5 # เราสามารถทำการ ทราานโพส ตัวอาเรย์เพื่อสลับเมทริกซ์จากแถวไปเป็นคอลัมน์
6 print(mtadj.T)
```

[88]

Python

```
... [[ 1  2  3  4]
      [ 5  6  7  8]
      [ 9 10 11 12]]
      [[ 1  5  9]
       [ 2  6 10]
       [ 3  7 11]
       [ 4  8 12]]
```

การคำนวณของ Vector บวก, ลบ, คูณ, ดอต

```
1 x = np.array([4, 5, 6])
2 y = np.array([1, 2, 3])
3
4 print('x+y=', (x+y)) # การบวก vector
5 print('x-y=', (x-y)) # การลบ vector
6 print('x*y=', (x*y)) # การคูณ vector
7 print('x.y=', np.dot(x,y)) # การดอต vector [4*1 + 5*2 + 8*3]
8 print('x.y=', x@y) # การดอต vector [4*1 + 5*2 + 8*3]
```

[101]

Python

```
... x+y= [5 7 9]
     x-y= [3 3 3]
     x*y= [ 4 10 18]
     x.y= 32
     x.y= 32
```

การเข้าถึงและเลือกสมาชิกในอาเรย์


การคำนวณของ Matrix

```
1 n = np.array([[4, 5, 8],[5, 7, 9]])
2 p = np.array([[1, 2, 3],[4, 5, 6]])
3
4 print(n)
5 print(p)
6
7 print('n+p=', (n+p)) # การบวก matrix
8 print('n-p=', (n-p)) # การลบ matrix
9 print('n*p=', (n*p)) # การคูณ matrix
10
11 # การ Dot Matrix มีเงื่อนไขว่า จะทำได้ต่อเมื่อจำนวน คอลัมน์ของตัวตั้ง ต้องเท่ากับ จำนวนแถวของตัวที่มา dot
12 t1 = np.array([[1, 2, 3], [4, 5, 6]])
13 t2 = np.array([[7, 8], [9, 10], [11, 12]])
14
15 print('t1.t2=', t1@t2)
16
```

[106]

Python

```
... [[4 5 8]
      [5 7 9]]
      [[1 2 3]
      [4 5 6]]
n+p= [[ 5  7 11]
      [ 9 12 15]]
n-p= [[3 3 5]
      [1 2 3]]
n*p= [[ 4 10 24]
      [20 35 54]]
t1.t2= [[ 58  64]
        [139 154]]
```



Module 4

โหลดและจัดการชุดข้อมูลด้วย ไลบรารี Pandas

- ติดตั้งและเรียกใช้งานไลบรารี Pandas
- โหลดชุดข้อมูลด้วย Pandas
- การเรียกดูข้อมูลใน DataFrame
- การเลือกและจัดการกับข้อมูลใน DataFrame
- การดูข้อมูลทางสถิติ
- การทำความสะอาดข้อมูล (Data Cleansing)

ติดตั้ง Pandas

```
1 pip install pandas
[2] ✓ 18.7s Python
```

... Collecting pandas
Using cached pandas-1.5.1-cp310-cp310-win_amd64.whl (10.4 MB)
Requirement already satisfied: python-dateutil≥2.8.1 in g:\trainingworkshop\pythonmlcpf\env\lib\site-packages (from pandas) (2.8.2)
Collecting pytz≥2020.1
Using cached pytz-2022.6-py2.py3-none-any.whl (498 kB)
Requirement already satisfied: numpy≥1.21.0 in g:\trainingworkshop\pythonmlcpf\env\lib\site-packages (from pandas) (1.23.4)
Requirement already satisfied: six≥1.5 in g:\trainingworkshop\pythonmlcpf\env\lib\site-packages (from python-dateutil≥2.8.1→pandas) (1.16.0)
Installing collected packages: pytz, pandas
Successfully installed pandas-1.5.1 pytz-2022.6
Note: you may need to restart the kernel to use updated packages.

WARNING: You are using pip version 21.2.3; however, version 22.3.1 is available.
You should consider upgrading via the 'g:\TrainingWorkshop\PythonMLCPF\env\Scripts\python.exe -m pip install --upgrade pip' command.

โหลดข้อมูลจากไฟล์ CSV ภายนอก

~ โหลดข้อมูลจากไฟล์ CSV ภายนอก




```
1 import pandas as pd
2
3 url = "https://raw.githubusercontent.com/fivethirtyeight/data/master/airline-safety/airline-safety.csv"
4
5 df = pd.read_csv(url)
6
7 df
8
```

[10] ✓ 0.8s

Python

	airline	avail_seat_km_per_week	incidents_85_99	fatal_accidents_85_99	fatalities_85_99	incidents_00_14	fatal_accidents_00_14	fatalities_00_14
0	Aer Lingus	320906734	2	0	0	0	0	0
1	Aeroflot*	1197672318	76	14	128	6	1	88
2	Aerolineas Argentinas	385803648	6	0	0	1	0	0
3	Aeromexico*	596871813	3	1	64	5	0	0
4	Air Canada	1865253802	2	0	0	2	0	0
5	Air France	3004002661	14	4	79	6	2	337
6	Air India*	869253552	2	1	329	4	1	158
7	Air New Zealand*	710174817	3	0	0	5	1	7
8	Alaska Airlines*	965346773	5	0	0	5	1	88
9	Alitalia	698012498	7	2	50	4	0	0
10	All Nippon Airways	1841234177	3	1	1	7	0	0
11	American*	5228357340	21	5	101	17	3	416

โหลดข้อมูลจากไฟล์ CSV ภายในโปรเจกต์



The screenshot shows a Jupyter Notebook interface with a file explorer on the left and a code cell in the center. The file explorer shows a project structure with folders 'env', 'NumpyLab', and 'PandasLab'. Inside 'PandasLab', there is a 'dataset' folder containing 'example.xls' and 'salary_food.csv', and a 'pandas_guide.ipynb' file. The code cell contains the following Python code:

```
1 df = pd.read_csv('dataset/salary_food.csv')
2 
3 df
```

The output of the code is a DataFrame with two columns: 'income' and 'food_expenses'. The DataFrame contains 14 rows of data. Below the code cell, there is a preview of the 'salary_food.csv' file, showing the same data as the DataFrame output.

	income	food_expenses
0	16	52
1	20	60
2	12	50
3	14	52
4	14	50
5	15	48
6	12	48
7	10	46
8	12	48
9	10	46
10	10	48
11	12	50
12	17	54
13	18	56

โหลดข้อมูลจากไฟล์ Excel ภายในโปรเจกต์

```
[22] 1 ติดตั้ง Library xlrd
      2 !pip install xlrd
      ✓ 1.7s Python
```

... Collecting xlrd
Downloading xlrd-2.0.1-py2.py3-none-any.whl (96 kB)
Installing collected packages: xlrd
Successfully installed xlrd-2.0.1

WARNING: You are using pip version 21.2.3; however, version 22.3.1 is available.
You should consider upgrading via the 'G:\TrainingWorkshop\PythonMLCPF\env\Scripts\python.exe -m pip install --upgrade pip' command.

```
[28] 1 df = pd.read_excel('dataset/example.xls')
      2 
      3 df
      ✓ 0.4s Python
```

...

	Day of Week	"Number of Crashes"
0	Sunday	13664
1	Monday	17279
2	Tuesday	17337
3	Wednesday	17394
4	Thursday	17954
5	Friday	19147
6	Saturday	15714

การเรียกดูข้อมูลใน DataFrame

~ การเรียกดูข้อมูลใน DataFrame



```
1 url = "https://raw.githubusercontent.com/fivethirtyeight/data/master/airline-safety/airline-safety.csv"
2
3 df = pd.read_csv(url)
4
5 # การเรียกดูข้อมูลส่วนหัวตาราง
6 df.head() # ค่าเริ่มต้นจะแสดง 5 แถวแรก
7 df.head(10) # ดึงมาแสดงผล 10 แถวแรก
8
9 # เรียกดูข้อมูลส่วนท้ายตาราง
10 df.tail() # ค่าเริ่มต้นจะแสดง 5 แถวสุดท้าย
11 df.tail(10) # ดึงมาแสดงผล 10 รายการสุดท้าย
12
13 # การเรียกดูรูปร่างของตาราง (shape)
14 # print(df)
15 df.shape # จะคืนค่าออกมาเป็น (แถว, คอลัมน์)
16
17 # สรุปรายละเอียดของตาราง
18 # df.info()
19
20 # สรุปข้อมูลทางสถิติ (count, mean, std, max, min , percent tile)
21 df.describe()
```

[41] ✓ 0.1s

Pythor

...	avail_seat_km_per_week	incidents_85_99	fatal_accidents_85_99	fatalities_85_99	incidents_00_14	fatal_accidents_00_14	fatalities_00_14
count	5.600000e+01	56.000000	56.000000	56.000000	56.000000	56.000000	56.000000
mean	1.384621e+09	7.178571	2.178571	112.410714	4.125000	0.660714	55.517857
std	1.465317e+09	11.035656	2.861069	146.691114	4.544977	0.858684	111.332751
min	2.593733e+08	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	4.740362e+08	2.000000	0.000000	0.000000	1.000000	0.000000	0.000000
50%	8.029089e+08	4.000000	1.000000	48.500000	3.000000	0.000000	0.000000
75%	1.847239e+09	8.000000	3.000000	184.250000	5.250000	1.000000	83.250000
max	7.139291e+09	76.000000	14.000000	535.000000	24.000000	3.000000	537.000000

การเลือกและจัดการข้อมูลใน DataFrame

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 df
```

[42]

✓ 0.1s

Python

...

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
...	...	...	...	...	...	...	...	...	...	...	...	...
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.0000	NaN	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.4500	NaN	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.0000	C148	C
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.7500	NaN	Q

891 rows × 12 columns

การเลือกข้อมูลบางคอลัมน์

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 result = df[['Name', 'Sex', 'Age']]
6
7 result
8
```

[48]

✓ 0.9s

Python

...

	Name	Sex	Age
0	Braund, Mr. Owen Harris	male	22.0
1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0
2	Heikkinen, Miss. Laina	female	26.0
3	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0
4	Allen, Mr. William Henry	male	35.0
...	...	...	...
886	Montvila, Rev. Juozas	male	27.0
887	Graham, Miss. Margaret Edith	female	19.0
888	Johnston, Miss. Catherine Helen "Carrie"	female	NaN
889	Behr, Mr. Karl Howell	male	26.0
890	Dooley, Mr. Patrick	male	32.0

891 rows × 3 columns

เลือกคอลัมน์

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 result = df[['Name', 'Sex', 'Age']]
6
7 result.drop(['Sex', 'Age'], axis=1)
8
```

[58] ✓ 0.1s

Python

...

	Name
0	Braund, Mr. Owen Harris
1	Cumings, Mrs. John Bradley (Florence Briggs Th...
2	Heikkinen, Miss. Laina
3	Futrelle, Mrs. Jacques Heath (Lily May Peel)
4	Allen, Mr. William Henry
...	...
886	Montvila, Rev. Juozas
887	Graham, Miss. Margaret Edith
888	Johnston, Miss. Catherine Helen "Carrie"
889	Behr, Mr. Karl Howell
890	Dooley, Mr. Patrick

891 rows × 1 columns

การเลือกแถวข้อมูลเป็นช่วง และการลบข้อมูลในแถวที่ไม่ต้องการ

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 # df.iloc[3:8]
6
7 # สามารถกำหนดเงื่อนไขในการแสดงผลแถวที่ต้องการ
8 # df[df['Age'] > 60]
9
10 df[(df['Age'] > 60) & (df['Sex'] == 'female')]
```

✓ 0.1s

Python

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
275	276	1	1	Andrews, Miss. Kornelia Theodosia	female	63.0	1	0	13502	77.9583	D7	S
483	484	1	3	Turkula, Mrs. (Hedwig)	female	63.0	0	0	4134	9.5875	NaN	S
829	830	1	1	Stone, Mrs. George Nelson (Martha Evelyn)	female	62.0	0	0	113572	80.0000	B28	NaN

การลบแถวข้อมูลที่ไม่ต้องการใน DataFrame

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 df.drop([2,3,4]).head()
```

67] ✓ 0.9s

Python

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583	NaN	Q
6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625	E46	S
7	8	0	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.0750	NaN	S

การแทนที่ข้อมูลใน DataFrame

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 df.replace({'Pclass': {1:'1st', 2:'2nd', 3:'3rd'}}).head(10)
6 df.replace(0, 'zero').head(10) # แทนที่ทั้ง DataFrame
```

[74]

✓ 0.1s

Python

...

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	zero	3	Braund, Mr. Owen Harris	male	22.0	1	zero	A/5 21171	7.25	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	zero	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	zero	zero	STON/O2. 3101282	7.925	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	zero	113803	53.1	C123	S
4	5	zero	3	Allen, Mr. William Henry	male	35.0	zero	zero	373450	8.05	NaN	S
5	6	zero	3	Moran, Mr. James	male	NaN	zero	zero	330877	8.4583	NaN	Q
6	7	zero	1	McCarthy, Mr. Timothy J	male	54.0	zero	zero	17463	51.8625	E46	S
7	8	zero	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.075	NaN	S
8	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	zero	2	347742	11.1333	NaN	S
9	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.0	1	zero	237736	30.0708	NaN	C

การดูข้อมูลทางสถิติ

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 print('Count→', df['Fare'].count())
6 print('Mean→', df['Fare'].mean())
7 print('STD→', df['Fare'].std())
8 print('Min→', df['Fare'].min())
9 print('Max→', df['Fare'].max())
```

[8] ✓ 0.1s Python

... Count→ 891
Mean→ 32.204207968574636
STD→ 49.6934285971809
Min→ 0.0
Max→ 512.3292

การดูข้อมูลทางสถิติ

สำหรับ Column ที่เป็นกลุ่ม เราสามารถนับจำนวนข้อมูลในแต่ละค่าได้เช่นกัน โดยใช้ method `value_counts()` ตัวอย่างแยกว่า ผู้โดยสาร ชั้น 1, 2 และ 3 ชั้นละกี่คน

```
1 url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv"
2
3 df = pd.read_csv(url)
4
5 df['Pclass'].value_counts()
```

[9] ✓ 0.4s Python

```
... 3    491
     1    216
     2    184
     Name: Pclass, dtype: int64
```

การทำความสะอาดข้อมูล (Data Cleansing)

ตัวอย่างพบว่าข้อมูลมีปัญหา ได้แก่ ข้อมูลว่าง NaN ข้อมูลผิดรูปแบบ ข้อมูลไม่ถูกต้อง และข้อมูลซ้ำ

1 `df = pd.read_csv('dataset/exercise.csv')`
2
3 `df`

[10] ✓ 0.4s

ข้อมูลว่าง

ข้อมูลผิดรูปแบบ

ข้อมูลซ้ำ

ข้อมูลไม่ถูกต้อง

	Date	User_ID	Sex	Age	Hight	Weight	Duration	Heart_Rate	Body_Temp
0	2021-10-01'	14733363	male	68.0	190.0	94	29	105	40.8
1	2021-10-02'	14861698	female	NaN	166.0	60	14	94	40.3
2	2021-10-03'	11179863	male	69.0	17.9	79	5	88	38.7
3	20211004	6180408	female	34.0	179.0	71	13	100	40.5
4	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
5	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
6	2021-10-06'	15130815	female	36.0	151.0	50	23	96	40.7
7	2021-10-07'	19602372	female	33.0	158.0	56	22	95	40.5
8	2021-10-08'	11117088	male	41.0	175.0	85	25	100	40.7
9	2021-10-09'	12132339	male	60.0	186.0	94	21	97	40.4
10	2021-10-10'	17964668	female	26.0	146.0	51	16	90	40.2

ทำความสะอาดค่าว่าง

ลบแถวที่มีข้อมูลว่าง NaN

```
1 df = pd.read_csv('dataset/exercise.csv')
2
3 df.dropna(inplace=True)
4
5 df
```

[11] ✓ 0.5s

Python

	Date	User_ID	Sex	Age	Hight	Weight	Duration	Heart_Rate	Body_Temp
0	2021-10-01'	14733363	male	68.0	190.0	94	29	105	40.8
2	2021-10-03'	11179863	male	69.0	17.9	79	5	88	38.7
3	20211004	16180408	female	34.0	179.0	71	13	100	40.5
4	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
5	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
6	2021-10-06'	15130815	female	36.0	151.0	50	23	96	40.7
7	2021-10-07'	19602372	female	33.0	158.0	56	22	95	40.5
8	2021-10-08'	11117088	male	41.0	175.0	85	25	100	40.7
9	2021-10-09'	12132339	male	60.0	186.0	94	21	97	40.4
10	2021-10-10'	17964668	female	26.0	146.0	51	16	90	40.2

แทนที่ข้อมูลว่าง NaN

```
1 df = pd.read_csv('dataset/exercise.csv')
2
3 df['Age'].fillna(-99, inplace=True)
4
5 df
```

[12] ✓ 0.5s

Python

	Date	User_ID	Sex	Age	Hight	Weight	Duration	Heart_Rate	Body_Temp
0	2021-10-01'	14733363	male	68.0	190.0	94	29	105	40.8
1	2021-10-02'	14861698	female	-99.0	166.0	60	14	94	40.3
2	2021-10-03'	11179863	male	69.0	17.9	79	5	88	38.7
3	2021-10-04'	16180408	female	34.0	179.0	71	13	100	40.5
4	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
5	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
6	2021-10-06'	15130815	female	36.0	151.0	50	23	96	40.7
7	2021-10-07'	19602372	female	33.0	158.0	56	22	95	40.5
8	2021-10-08'	11117088	male	41.0	175.0	85	25	100	40.7
9	2021-10-09'	12132339	male	60.0	186.0	94	21	97	40.4
10	2021-10-10'	17964668	female	26.0	146.0	51	16	90	40.2

ทำความสะอาดค่าที่ผิด

```
1 df = pd.read_csv('dataset/exercise.csv')
2
3 df.loc[2, 'Hight'] = 179 # แทนที่ค่าที่ถูกต้องลงไป
4
5 df
6
7 # df.drop([2,2]) # หรือลบแถวที่ต้องการทิ้งไป
8
```

[30] ✓ 0.6s Python

...

	Date	User_ID	Sex	Age	Hight	Weight	Duration	Heart_Rate	Body_Temp
0	2021-10-01'	14733363	male	68.0	190.0	94	29	105	40.8
1	2021-10-02'	14861698	female	NaN	166.0	60	14	94	40.3
2	2021-10-03'	11179863	male	69.0	179.0	79	5	88	38.7
3	20211004	16180408	female	34.0	179.0	71	13	100	40.5
4	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
5	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
6	2021-10-06'	15130815	female	36.0	151.0	50	23	96	40.7
7	2021-10-07'	19602372	female	33.0	158.0	56	22	95	40.5
8	2021-10-08'	11117088	male	41.0	175.0	85	25	100	40.7
9	2021-10-09'	12132339	male	60.0	186.0	94	21	97	40.4
10	2021-10-10'	17964668	female	26.0	146.0	51	16	90	40.2

ทำความสะอาดค่าที่ผิดปกติ

```
1 df = pd.read_csv('dataset/exercise.csv')
2 
3 df.drop([3,3]) # ลบแถวที่ต้องการทิ้งไป
```

[31]

✓ 0.6s

Python

...

	Date	User_ID	Sex	Age	Hight	Weight	Duration	Heart_Rate	Body_Temp
0	2021-10-01'	14733363	male	68.0	190.0	94	29	105	40.8
1	2021-10-02'	14861698	female	NaN	166.0	60	14	94	40.3
2	2021-10-03'	11179863	male	69.0	17.9	79	5	88	38.7
4	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
5	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
6	2021-10-06'	15130815	female	36.0	151.0	50	23	96	40.7
7	2021-10-07'	19602372	female	33.0	158.0	56	22	95	40.5
8	2021-10-08'	11117088	male	41.0	175.0	85	25	100	40.7
9	2021-10-09'	12132339	male	60.0	186.0	94	21	97	40.4
10	2021-10-10'	17964668	female	26.0	146.0	51	16	90	40.2

ทำความสะอาดรายการที่ซ้ำ

```
1 df = pd.read_csv('dataset/exercise.csv')
2
3 df.drop_duplicates(inplace=True) # ลบแถวที่ซ้ำออกไป
4 💡
5 df
```

[32]

✓ 0.6s

Python

...

	Date	User_ID	Sex	Age	Hight	Weight	Duration	Heart_Rate	Body_Temp
0	2021-10-01'	14733363	male	68.0	190.0	94	29	105	40.8
1	2021-10-02'	14861698	female	NaN	166.0	60	14	94	40.3
2	2021-10-03'	11179863	male	69.0	17.9	79	5	88	38.7
3	20211004	16180408	female	34.0	179.0	71	13	100	40.5
4	2021-10-05'	17771927	female	27.0	154.0	58	10	81	39.8
6	2021-10-06'	15130815	female	36.0	151.0	50	23	96	40.7
7	2021-10-07'	19602372	female	33.0	158.0	56	22	95	40.5
8	2021-10-08'	11117088	male	41.0	175.0	85	25	100	40.7
9	2021-10-09'	12132339	male	60.0	186.0	94	21	97	40.4
10	2021-10-10'	17964668	female	26.0	146.0	51	16	90	40.2

Demo Cleansing

A	B	C	D	E
id	Datetime	n_id	n_val	machine_id
1	2022-11-13	10:06:00	2000	Air_Pump_Ozone
2	2022-11-13	10:00:00	10000	Air_Pump_Ozone
3	2022-11-13	9:15:00	1200	Air_Pump_Ozone
4	2022-11-13	9:00:00	500	Air_Pump_Ozone
5	2022-11-13	8:30:00	1100	Air_Pump_Ozone
6	2022-11-13	8:00:00	1000	Air_Pump_Ozone



```
1 import pandas as pd
2
3 df = pd.read_csv('dataset/Electric.csv')
4
5 print(df)
6
7 filt = (
8     (df['Datetime'] == '2022-11-13') &
9     (df['n_val'] >= df['n_val'].iloc[-1]) &
10    (df['n_val'] <= df['n_val'].iloc[0])
11 )
12
13 print()
14
15 print(df[filt])
16
```

[36] ✓ 0.4s

Python

```
...
   id  Datetime    n_id  n_val  machine_id
0   1  2022-11-13  10:06:00  2000  Air_Pump_Ozone
1   2  2022-11-13  10:00:00  10000  Air_Pump_Ozone
2   3  2022-11-13   9:15:00   1200  Air_Pump_Ozone
3   4  2022-11-13   9:00:00    500  Air_Pump_Ozone
4   5  2022-11-13   8:30:00   1100  Air_Pump_Ozone
5   6  2022-11-13   8:00:00   1000  Air_Pump_Ozone

   id  Datetime    n_id  n_val  machine_id
0   1  2022-11-13  10:06:00  2000  Air_Pump_Ozone
2   3  2022-11-13   9:15:00   1200  Air_Pump_Ozone
4   5  2022-11-13   8:30:00   1100  Air_Pump_Ozone
5   6  2022-11-13   8:00:00   1000  Air_Pump_Ozone
```

• LIVE

รับชมฟรี



#3

พื้นฐาน

แมชชีนเลิร์นนิ่ง

อัปเดตปี

PYTHON

for Machine Learning

2024



อาจารย์สามิตร
สถาบันไอทีจีเนียส

29 JAN 2024 20.30-22.30 PM

PYTHON

for Machine Learning

วันที่

3



อ.สาวิตร โกยม



สถาบันไอทีจีเนียส

Module 5

การพล็อตกราฟด้วยไลบรารี Matplotlib

- ติดตั้งและเรียกใช้งานไลบรารี Matplotlib
- การวาดกราฟเส้น
- การแสดงชื่อกราฟและชื่อแกน
- สร้างแผนภาพการกระจาย (Scatter plot)
- สร้างกราฟแท่ง (Bar chart)
- สร้างกราฟฮิสโทแกรม (Histogram)
- สร้างแผนภูมิวงกลม (Pie chart)



การพล็อตกราฟด้วย Matplotlib

Matplotlib เป็นไลบรารีสำหรับภาษาไพทอนที่ช่วยในการแสดงภาพนิ่ง ภาพเคลื่อนไหวและทำงานโต้ตอบกับผู้ใช้ ซึ่งใช้บ่อยสำหรับ การสำรวจและแสดงภาพข้อมูลจากอาเรย์ให้อยู่ในรูปแบบของกราฟ เช่น กราฟเส้น แผนภาพการกระจาย กราฟแท่ง ฮิสโทแกรม และแผนภูมิวงกลม

ติดตั้ง Matplotlib ผ่าน pip

```
pip install matplotlib
```

การเรียกใช้งาน Matplotlib

```
import matplotlib.pyplot as plt
```

การวาดกราฟเส้น


กราฟเส้น (Linear Plot) เป็นการลากเส้นเชื่อมโยงระหว่างจุดที่แสดงความสัมพันธ์ของข้อมูลในแนวแกน X และแกน Y โดยมีขั้นตอนในเบื้องต้นดังนี้

1. กำหนดข้อมูลในแนวแกน X ซึ่งอาจเป็นแบบลิสต์ ทูเพิล หรืออาร์เรย์ (NumPy)
2. กำหนดข้อมูลในแนวแกน Y ซึ่งอาจเป็นแบบลิสต์ ทูเพิล หรืออาร์เรย์ (NumPy)
3. สร้างกราฟเส้นด้วยฟังก์ชัน plot() ของไลบรารี Matplotlib โดยนำข้อมูลของแนวแกน X และ Y มากำหนดให้กับมัน
4. สั่งแสดงกราฟด้วยฟังก์ชัน show()


```
import numpy as np
import matplotlib.pyplot as plt
```

```
x = np.array([2014, 2015, 2016, 2017, 2018, 2019, 2020])
y = np.array([229, 514, 1050, 2456.2, 3456.2, 4653.4, 4052.6])
```

```
plt.plot(x, y)
plt.show()
```



การวาดกราฟเส้น




การวาดกราฟเส้นจากข้อมูล CSV

การวาดกราฟเส้นจาก CSV

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3
4 df = pd.read_csv('datasets/gdp.csv')
5
6 plt.plot(df['years'], df['gdp'])
7 plt.show()
```

[5] ✓ 0.1s

Python



การกำหนดสีของกราฟ


มีองค์ประกอบบางอย่างของกราฟที่เราสามารถกำหนดสีให้กับมันได้ ทั้งนี้ก็เพื่อแยกความแตกต่างของข้อมูลแต่ละอย่างให้ชัดเจนยิ่งขึ้น ดังนี้

- รูปแบบการกำหนดสีที่ Matplotlib รองรับคือ
 - **Color Name** เช่น `color='red'` หรือ `color='orange'` เป็นต้น
 - **Single Character** คือการกำหนดด้วยอักขระตัวเดียว ซึ่งมีเพียง 8 สี เท่านั้นคือ

อักขระ	ชื่อสี	แนวทางการใช้งาน
r	red	<code>color='r'</code>
g	green	<code>color='g'</code>
b	blue	<code>color='b'</code>
c	cyan	<code>c='c'</code>
m	magenta	<code>c='m'</code>
y	yellow	<code>c='y'</code>
w	white	<code>c='w'</code>
k	black	<code>c='k'</code>

- **#Hex** โดยกำหนดค่าแบบสตริงให้เริ่มต้นด้วย # แล้วตามอักขระ a-f หรือ 0-9 จำนวน 6 ตัว เช่น `color='#af09c7'`
- **RGB** กำหนดค่าระหว่าง 0-1 สำหรับระดับสีแดง เขียว และน้ำเงิน ในแบบ (r, g, b) หรือ (a, r, g, b) เมื่อ a คือค่า alpha เช่น
`color=(0.3, 0.4, 0.9)`
`color=(0.4, 0.5, 0.75, 0.6)`

การหนดจุด mark และรูปแบบของเส้น



การกำหนด Label, Title และ Tick




- **xlabel**('ข้อความ', color, alpha, fontsize)
- **ylabel**('ข้อความ', color, alpha, fontsize)
- **title**('ข้อความ', color, alpha, fontsize)
- **xticks**(rotation='vertical/horizontal/degree', color, alpha, fontsize)
- **yticks**(rotation='vertical/horizontal/degree', color, alpha, fontsize)

การวาดกราฟแบบ Scatter

Scatter เป็นการวาดกราฟแบบกระจายกลุ่มข้อมูลของ 2 ตัวแปรในแนวแกน X และ Y โดยทั่วไปแล้ว กราฟแบบ Scatter มักใช้เพื่อเปรียบเทียบความสัมพันธ์ระหว่างข้อมูลของตัวแปรหนึ่งกับอีกตัวแปรหนึ่ง ซึ่งใน Machine Learning เราต้องนำกราฟแบบ Scatter ไปใช้อยู่บ่อย ๆ โดยแนวทางการวาดกราฟมีดังนี้

- กราฟชนิดนี้เราต้องกำหนดข้อมูลในแนวแกน X และ Y ให้เป็นแบบรายการ เช่น ลิสต์ ทูเพิล หรือ อาร์เรย์ และต้องมีจำนวนเท่ากันทั้งสองแนวแกน
- วาดกราฟด้วยฟังก์ชัน `plt.scatter()` โดยอาร์กิวเมนต์พื้นฐานก็คล้ายกับกราฟแบบ Linear ดังที่กล่าวมาแล้ว ซึ่งอันที่นิยมนำมาใช้กับกราฟชนิดนี้อยู่บ่อย ๆ เช่น `color`, `marker` เป็นต้น หรืออาจปรับขนาดของ maker ด้วยอาร์กิวเมนต์ `s` เช่น `s=100`

การวาดกราฟแบบ Scatter




การวาดกราฟแท่ง (Bar Chart)


```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 x = np.array([2014, 2015, 2016, 2017, 2018, 2019, 2020])
5 y = np.array([229, 514, 1050, 2456.2, 3456.2, 4653.4, 4052.6])
6
7 plt.bar(x, y)
8 plt.show()
```

[10] ✓ 0.1s


Python




การวาดกราฟแท่ง (Bar Chart)



การวางแผนภูมิวงกลม (Pie Chart)






Module 6


การจัดเตรียมข้อมูลสำหรับ Machine Learning

- การใช้ไลบรารี Scikit-Learn สำหรับ ML
- ลักษณะข้อมูลสำหรับ ML
- การกำหนดแหล่งข้อมูลสำหรับ ML
- การตรวจสอบค่าที่สูญหาย (Missing Value)
- การเข้ารหัสสตริงให้เป็นตัวเลข (Encoding)
- การปรับสเกลของข้อมูล
- การแบ่งข้อมูลเป็นชุด Train และ Test
- ความสัมพันธ์ระหว่างคอลัมน์



การจัดเตรียมข้อมูลสำหรับ ML

ขั้นตอนการทำ Machine Learning




การใช้ไลบรารี Scikit-Learn สำหรับ ML

Scikit-Learn หรือเรียกตามชื่อโมดูลเป็น SkLearn คือไลบรารีสำหรับ Machine Learning ที่ได้รับความนิยมสูงสุด ซึ่งสร้างโดยทีมนักพัฒนาของ Google เพื่อใช้งานร่วมกับไลบรารีพื้นฐานที่มีอยู่แล้วของ Data Science อย่างเช่น NumPy รวมถึง Pandas ทั้งนี้หากเราติดตั้งชุดแพ็คเกจ Anaconda ก็จะมี Scikit-Learn รวมอยู่ด้วย จึงสามารถใช้งานได้ทันที

ไลบรารี Scikit-Learn ประกอบด้วยโมดูล คลาส และฟังก์ชันจำนวนมาก ซึ่งเราต้องเลือกอิมพอร์ตให้สอดคล้องกับวัตถุประสงค์ของการใช้งาน โดยชื่อโมดูลจะเริ่มต้นด้วยคำว่า sklearn ทั้งหมด ทั้งนี้วิธีการทำนายผลด้วย Scikit-Learn ของแต่ละโมเดลส่วนใหญ่จะใช้หลักการที่คล้ายคลึงกัน




การใช้ไลบรารี Scikit-Learn สำหรับ ML



Dataset (ชุดข้อมูล)

คือ การนำข้อมูลที่มีคุณสมบัติเหมือนกันมาจัดเป็นชุดให้ถูกต้องตามลักษณะโครงสร้างข้อมูล โดยชุดข้อมูลพื้นฐานที่ใช้กันอย่างแพร่หลายทางด้าน Machine Learning ได้แก่ชุดข้อมูลดอกไม้ (Iris Dataset) กับ ชุดข้อมูลลายมือตัวเลขอารบิก (MNIST Dataset)

1.ชุดข้อมูลดอกไม้ (Iris Dataset) เป็นชุดข้อมูลพื้นฐานที่ใช้กันอย่างแพร่หลายในด้านสถิติและ Machine Learning โดยชุดข้อมูลดอกไม้ประกอบไปด้วยดอกไม้ 3 สายพันธุ์ได้แก่ Versicolor , Setosa , Virginica ดังภาพประกอบด้านล่าง



Dataset (ชุดข้อมูล)

คุณสมบัติหรือ Feature ในชุดข้อมูลดอกไม้

คือการวัดความกว้างและความยาวของกลีบใบที่เรียกว่า Sepal (กลีบเลี้ยง) และ Petal (กลีบดอก) (มีหน่วยเป็นเซนติเมตร cm.)

iris setosa



petal

sepal

iris versicolor



petal

sepal

iris virginica



petal

sepal

Dataset (ชุดข้อมูล)

ตัวอย่างการเก็บชุดข้อมูลดอกไม้



Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

Features
(attributes, measurements, dimensions)

Class labels
(targets)

Petal


Sepal

	A	B	C	D	E
1	Sepal Length	Sepal Width	Petal Length	Petal Width	Class
2	5.1	3.5	1.4	0.2	Iris-setosa
3	4.9	3	1.4	0.2	Iris-setosa
4	4.7	3.2	1.3	0.2	Iris-setosa
5	4.6	3.1	1.5	0.2	Iris-setosa
6	5	3.6	1.4	0.2	Iris-setosa
7	5.4	3.9	1.7	0.4	Iris-setosa
8	4.6	3.4	1.4	0.3	Iris-setosa
9	5	3.4	1.5	0.2	Iris-setosa
10	4.4	2.9	1.4	0.2	Iris-setosa
11	4.9	3.1	1.5	0.1	Iris-setosa
12	5.4	3.7	1.5	0.2	Iris-setosa
13	4.8	3.4	1.6	0.2	Iris-setosa
14	4.8	3	1.4	0.1	Iris-setosa
15	4.3	3	1.1	0.1	Iris-setosa
16	5.8	4	1.2	0.2	Iris-setosa
17	5.7	4.4	1.5	0.4	Iris-setosa
18	5.4	3.9	1.3	0.4	Iris-setosa
19	5.1	3.5	1.4	0.3	Iris-setosa
20	5.7	3.8	1.7	0.3	Iris-setosa
21	5.1	3.8	1.5	0.3	Iris-setosa
22	5.4	3.4	1.7	0.2	Iris-setosa
23	5.1	3.7	1.5	0.4	Iris-setosa
24	4.6	3.6	1	0.2	Iris-setosa
25	5.1	3.3	1.7	0.5	Iris-setosa

- **Class Label / Target** คือ ชื่อข้อมูลที่ต้องการทราบเป็นผลลัพธ์ (Output) เช่น ชื่อสายพันธุ์ดอกไม้ 3 ชนิด
- **Attribute / Features** คือ คุณสมบัติของดอกไม้แต่ละสายพันธุ์ (ความยาว ความสูง หน่วยเซนติเมตร)

Dataset (ชุดข้อมูล)

2.ชุดข้อมูลลายมือตัวเลขอารบิก (MNIST Dataset) คือ ชุดข้อมูลลายมือตัวเลขอารบิกเลข 0–9 มีขนาดรูปภาพ 28 x 28 Pixels มีข้อมูลในชุดเรียนรู้จำนวน 60,000 รูปภาพและข้อมูลชุดทดสอบจำนวน 10,000 รูปภาพ ดังภาพประกอบด้านล่าง




- **Class Label / Target** คือ ชื่อข้อมูลที่ต้องการทราบเป็นผลลัพธ์ (Output) คือตัวเลข 0–9
- **Attribute / Features** คือ ภาพวาดลายมือตัวเลขอารบิกแต่ละตัว

การแบ่งข้อมูลเป็นชุด Train และ Test

กระบวนการ Machine Learning จะแบ่งข้อมูลสำคัญๆออกเป็น 2 ส่วน คือ


ข้อมูลชุดเรียนรู้ (Training Set) ถูกนำไปเรียนรู้ด้วยวิธีการเรียนรู้เครื่องจักรเพื่อสร้างเป็นโมเดล (Model) จะประกอบไปด้วย label / class เพื่อบอกว่าข้อมูลชุดนี้คืออะไร เช่น ชุดข้อมูลตัวเลข 0–9 , ข้อมูลสายพันธุ์สุนัข เป็นต้น

ข้อมูลชุดทดสอบ (Test Set) ใช้ทดสอบโมเดลที่สร้างขึ้น หากโมเดลที่ทดสอบมีประสิทธิภาพดีจึงจะนำไปใช้งานจริง



- *ในกรณีที่ไม่มี การแบ่งข้อมูลเป็น 2 ส่วนสามารถเขียนโปรแกรมเพื่อแบ่งข้อมูลได้โดยแบ่งข้อมูลเป็น 75% สำหรับเรียนรู้และอีก 25% สำหรับทดสอบ
- ดาวน์โหลด MNIST DataSet ตัวเต็มได้ที่ <https://osf.io/jda6s/>

การแบ่งข้อมูลเป็นชุด Train และ Test



การติดตั้ง Scikit-Learn และเรียกดูข้อมูล DataSets ตัวอย่าง

ติดตั้ง scikitlearn

```
1 pip install scikit-learn
2
```

[]

Python

load datasets package from scikit-learn

```
1 from sklearn import datasets
2
3 dir(datasets)
4
5 [data for data in dir(datasets) if data.startswith("load")]
```

[4]

✓ 0.4s

Python

```
... ['load_boston',
      'load_breast_cancer',
      'load_diabetes',
      'load_digits',
      'load_files',
      'load_iris',
      'load_linnerud',
      'load_sample_image',
      'load_sample_images',
      'load_svmlight_file',
      'load_svmlight_files',
      'load_wine']
```

SplitData

```
1 from sklearn.datasets import load_iris
2 from sklearn.model_selection import train_test_split
3
4 iris_dataset=load_iris()
5
6 # x_train,x_test,y_train,y_test = train_test_split(iris_dataset['data'],iris_dataset['target'],random_state=0)
7
8 x_train,x_test,y_train,y_test = train_test_split(iris_dataset["data"],iris_dataset["target"],test_size=0.2,
9 random_state=0)
10 print(x_train.shape)
11 print(x_test.shape)
12 print(y_train.shape)
13 print(y_test.shape)
14
15 # 150
16 #train 80% = 120
17 #test 20% = 30
```

[12] ✓ 0.4s Python

... (120, 4)
(30, 4)
(120,)
(30,)

PYTHON

for Machine Learning

วันที่

4



อ.สาวิตร โทยม



สถาบันไอทีจีเนียส

• LIVE

รับชมฟรี



#4

พื้นฐาน

แมชชีนเลิร์นนิ่ง

PYTHON

for

Machine Learning


อัปเดตปี

2024



อาจารย์สามิตร
สถาบันไอทีจีเนียส

05 FEB 2024 20.30-22.30 PM




Module 7

โมเดล Linear Regression

- พื้นฐานของสมการเส้นตรง
- Linear Regression และความสัมพันธ์ของข้อมูล
- Simple Linear Regression
- การทำนายผลด้วย Scikit-Learn
- การประเมินโมเดล (Model Evaluation)
- Multiple Linear Regression
- Polynomial Regression

การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)



$$y = a + bx$$

x = ตัวแปรอิสระ

y = ตัวแปรตาม

- คนที่รอบคอใหญ่ เอวมักจะใหญ่ตาม
- นักเรียนที่ได้คะแนนสอบวิชาคณิตศาสตร์สูง มักจะได้คะแนนวิชาฟิสิกส์สูงด้วย
- ครอบครัวที่มีรายได้สูงก็จะมีค่าใช้จ่ายค่าอาหารสูงตาม

การวิเคราะห์การถดถอยเชิงเส้น เป็นการคำนวณหาความสัมพันธ์ระหว่างตัวแปร 2 ตัวแปร คือ

- ตัวแปรที่เราทราบค่า (Predictor : x)
 - และตัวแปรที่เราไม่ทราบค่า (Response: y)
- ซึ่งเป็นความสัมพันธ์แบบเชิงเส้น (Linear) โดยการคำนวณจากค่า x และ y ที่มีความสัมพันธ์กันจะใช้สมการของ Linear Regression คือ

การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)


$$y = a + bx$$

y = ตัวแปรตาม (เป็นตัวแปรเชิงปริมาณ)

x = ตัวแปรอิสระ (เป็นตัวแปรเชิงปริมาณ)

a = จุดตัดบนแกน y

b = ค่าสัมประสิทธิ์ของการถดถอยหรือค่าความชัน




$$a = \frac{\sum y - b \sum x}{n}$$

สูตรหา a และ b

$$b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}$$

การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)


การวิเคราะห์การถดถอยเชิงเส้นต้องมีการเก็บจำนวน Sample space จำนวนมากพอ หรือเขียนโปรแกรมกำหนดค่าให้ได้กลุ่มตัวอย่างของข้อมูลให้ได้เยอะที่สุดนั่นคือ มี x และ y ที่มีความสัมพันธ์กันหลายๆ ครั้งเพื่อนำมาหาสมการความสัมพันธ์ (สามารถ LAB Python Linear Regression ประกอบความเข้าใจได้) ประเภทของความสัมพันธ์แบ่งได้ดังนี้



หมายถึงค่าของตัวแปร x , y มีทิศทางเดียวกันส่งผลให้เมื่อค่า x เพิ่มขึ้น ค่า y ก็เพิ่มตามไปด้วยหรือเรียกว่า การแปรผันตรง

ตัวอย่างแผนภาพการกระจาย (Scatter Plot) ความสัมพันธ์เส้นตรงทางบวก

การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)



หมายถึงค่าของตัวแปร x , y มีทิศทางตรงข้ามกันส่งผลให้เมื่อค่า x ลดลง ค่า y เพิ่มขึ้นหรือค่า x เพิ่มขึ้นแต่ค่า y ลดลงเรียกว่า การแปรผกผัน

ตัวอย่างแผนภาพการกระจาย (Scatter Plot) ความสัมพันธ์เส้นตรงทางลบ

ตัวอย่างการฝึกวิเคราะห์แบบ Linear Regression

NO.	รายได้ (x)	ค่าอาหาร (y)
1	16	52
2	20	60
3	12	50
4	14	52
5	14	50
6	15	48
7	12	48
8	10	46
9	10	48
10	12	50
11	17	54
12	18	56

จากการสุ่มบุคคลมา 12 คน แล้วบันทึกรายได้ต่อเดือนของบุคคล (หน่วยเป็นพันบาท) รายจ่ายค่าอาหารต่อเดือน (หน่วยเป็นร้อยบาท)

จากนั้นนำข้อมูลของ 10 คนแรกมาสร้างโมเดล Simple linear regression และจะทดสอบโมเดล โดยใช้ข้อมูลรายได้ต่อเดือนของคนที่ 11 และ 12 มาคำนวณหา ค่าอาหารว่าตรงกับผลสำรวจหรือไม่ ถ้าใกล้เคียงก็แสดงว่าโมเดลที่ได้มีความแม่นยำพอที่จะนำไปใช้ทำนายในอนาคต

วิธีทำ

รายได้เป็นตัวแปรอิสระกำหนดให้เป็น (x)
และค่าอาหารเป็นตัวแปรตามกำหนดให้เป็น (y)

จากนั้นนำข้อมูล x และ y ของ 10 คนแรกในตารางมา
คำนวณหาค่า a และ b

$$y = a + bx$$

$$b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}$$

$$a = \frac{\sum y - b \sum x}{n}$$

ตัวอย่างการฝึกวิเคราะห์แบบ Linear Regression

1. หาผลรวม ผลคูณ และค่ากำลังสอง ลงในตาราง

NO.	รายได้ (x)	ค่าอาหาร (y)	x ²	xx	y ²
1	16	52	256	832	2704
2	20	60	400	1200	3600
3	12	50	144	600	2500
4	14	52	196	728	2704
5	14	50	196	700	2500
6	15	48	225	720	2304
7	12	48	144	576	2304
8	10	46	100	460	2116
9	10	48	100	480	2304
10	12	50	144	600	2500
รวม	135	504	1905	6896	25536

2. คำนวณหาค่าความชันจากสูตร

$$b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}$$

n = 10 (จำนวนข้อมูล) และ $\sum$ คือผลรวมช่องล่างสุดของตาราง

$$\begin{aligned} b &= 10(6896) - (135 \times 504) / (10 \times 1905) - 135^2 \\ &= 68960 - 68040 / 19050 - 18255 \\ &= 920 / 825 \\ &= 1.11 \end{aligned}$$

3. คำนวณจุดตัดบนแกน y จากสูตร

$$a = \frac{\sum y - b \sum x}{n}$$

$$\begin{aligned} a &= 504 - (1.11 \times 135) / 10 \\ &= 504 - 149.85 / 10 \\ &= 354.15 / 10 \\ &= 35.41 \end{aligned}$$

ตัวอย่างการฝึกวิเคราะห์แบบ Linear Regression

2. คำนวณหาค่าความชันจากสูตร

$$b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}$$

$n = 10$ (จำนวนข้อมูล) และ $\sum$ คือผลรวมช่องล่างสุดของตาราง

$$\begin{aligned} b &= 10(6896) - (135 \times 504) / (10 \times 1905) - 135^2 \\ &= 68960 - 68040 / 19050 - 18255 \\ &= 920 / 825 \\ &= 1.11 \end{aligned}$$

3. คำนวณจุดตัดบนแกน y จากสูตร

$$a = \frac{\sum y - b \sum x}{n}$$

$$\begin{aligned} a &= 504 - (1.11 \times 135) / 10 \\ &= 504 - 149.85 / 10 \\ &= 354.15 / 10 \\ &= 35.41 \end{aligned}$$

4. แทนค่า a และ b ก็จะได้โมเดล Simple Linear Regression คือ

$$y = a + bx$$

$$y = 35.41 + 1.11x$$

11	17	54
12	18	56

5. ทดสอบโมเดลโดยนำรายได้ (x) ของคนที่ 11 และ 12 มาแทนที่ลงในโมเดลก็จะได้ค่าอาหาร (y) ดังนี้

$$\text{ค่าอาหาร (y) ของคนที่ 11} = 35.41 + 1.11 \times 17 = \mathbf{54.28}$$

ผลทำนายคือ 5,428 บาท

$$\text{ค่าอาหาร (y) ของคนที่ 12} = 35.41 + 1.11 \times 18 = \mathbf{55.39}$$

ผลทำนายคือ 5,539 บาท

ในทางสถิติจะมีการคำนวณหาค่า R^2 (R Square) คือสัมประสิทธิ์การตัดสินใจ (Coefficient of determination) ว่าอาหารมีความแปรผันตามเงินเดือนที่เปอร์เซ็นต์ เพื่อตรวจสอบความแม่นยำอีกครั้ง

สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

1. โหลดข้อมูลการสำรวจ

โหลดข้อมูลการสำรวจ

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 from sklearn.linear_model import LinearRegression
5
6 df = pd.read_csv('datasets/salary_with_food.csv')
7 df
```

[6] ✓ 0.4s Python

	income	food_expenses
0	16	52
1	20	60
2	12	50
3	14	52
4	14	50
5	15	48
6	12	48
7	10	46
8	10	48
9	12	50
10	17	54
11	18	56

สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn


2. ตรวจสอบและทำความสะอาดข้อมูล

3. เลือกฟิลด์ Feature และ Target ตัวอย่างนี้เราจะสร้างโมเดลด้วยอัลกอริทึม LinearRegression ซึ่งเป็น Supervised machine learning ประเภท Regression ที่ใช้ข้อมูลจากฟิลด์คุณลักษณะเฉพาะ (Feature) และฟิลด์เป้าหมายหรือเอาต์พุต (Target) ส่วนใน Classification จะเรียกว่า Label หรือเฉลย ไปใช้ในการสอน (Train) และการทดสอบ (Test)

	Feature	Target
	income	food_expenses
0	16	52
1	20	60
2	12	50
3	14	52
4	14	50
5	15	48
6	12	48
7	10	46
8	10	48
9	12	50
10	17	54
11	18	56

สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

4. ตรวจสอบข้อมูลด้วยแผนภาพการกระจาย (Scatter Plot)



สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

5. แบ่งข้อมูลสำหรับสอน (Train) และทดสอบ (Test)

```
1 X = df[['income']]
2 y = df[['food_expenses']]
3 X_train = X[:10]
4 X_test = X[-2:]
5 y_train = y[:10]
6 y_test = y[-2:]
7
```

สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

6. สร้างออบเจกต์อัลกอริทึม LinearRegression

```
model = LinearRegression() #สร้างอินสแตนซ์ของคลาส LinearRegression
```

7. สอนอัลกอริทึม ใช้ method fit() นำข้อมูล X_train และ y_train มาสอนให้อัลกอริทึมเรียนรู้ความสัมพันธ์ของข้อมูลตัวแปรอิสระและตัวแปรตาม แล้วสร้างโมเดลสมการเส้นตรง

```
model.fit(X_train, y_train)
```

8. ทดสอบโมเดล ใช้ method predict() นำข้อมูลจาก X_test คือรายได้ของคนที่ 11 และ 12 เข้าไปให้โมเดลทำนาย แล้วพิมพ์ผลลัพธ์ออกมา

```
Print("Predict : " , model.predict(X_test))
```

ผลที่ได้คือ Predict : [54.3030303] [55.41818182] จากนั้นให้ลองเปรียบเทียบกับค่าอาหารที่สำรวจไว้ของคนที่ 11 และ 12 คือ 54 และ 56 ซึ่งถือว่าใกล้เคียง


สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

9. ประเมินผลโมเดล

```
1 print("Coefficients: ", model.coef_) # หาค่าสัมประสิทธิ์ความชัน
2 print("Intercept:", model.intercept_) # หาค่าจุดตัดบนแกน y
3 print("R-Squared score:", model.score(X_test, y_test)) # R-Square ของการทำนาย
4 .
```


[11] ✓ 0.3s

```
... Coefficients: [[1.11515152]]
Intercept: [35.34545455]
R-Squared score: 0.7848301193755732
```



สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

10. วาดผลลัพธ์ของโมเดล



สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

11. บันทึกโมเดล

MatplotlibLab

datasets

matplotlib_guide.ipynb

NumpyLab

PandasLab

regression

RegressionModelLab

datasets

salary_foo_model.joblib

simple_regression.ipynb

ScikitlearnLab

บันทึกโมเดล

ติดตั้ง joblib

1

`pip install joblib`

[15]

✓ 1.2s

... Requirement already satisfied: joblib in g:\trainingworkshop\pythonmlclass\env\lib\site-packages (1.2.0)
Note: you may need to restart the kernel to use updated packages.

เรียกใช้งาน joblib

▷

1

`from joblib import dump`

2

3

`dump(model, 'salary_foo_model.joblib')`

4

5

`['salary_foo_model.joblib']`

[16]

✓ 0.5s

... ['salary_foo_model.joblib']

สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

12. โหลดโมเดล




```
1 from sklearn.linear_model import LinearRegression
2 from joblib import load
3
4 myModel = load('salary_foo_model.joblib')
5 myModel.predict([[13],[21]])
```

[20] ✓ 0.4s Python

... g:\TrainingWorkshop\PythonMLClass\env\lib\site-packages\sklearn\base.py:450: UserWarning: X does not have valid feature names, but LinearRegression was fitted with feature names
warnings.warn(
array([[49.84242424],
 [58.76363636]]))

สร้างโมเดลการถดถอยเชิงเส้นด้วย scikit-learn

13. การนำโมเดลไปใช้งานภายนอก



The screenshot shows a Jupyter Notebook window titled "PythonMLCPF". The left sidebar displays a file explorer with a project structure including folders like "env", "MatplotlibLab", "MyModelTrained", "NumpyLab", "PandasLab", "RegressionModelLab", and "ScikitLearnLab". Under "RegressionModelLab", there is a "datasets" folder containing "salary_with_food.csv" and "salary_food_model.joblib", and a "simple_regression.ipynb" file.

The main notebook area shows a code cell with the following Python code:

```
1 print("Coefficients: ", model.coef_) # หาค่าสัมประสิทธิ์ความชัน
2 print("Intercept: ", model.intercept_) # ค่าจุดตัดบนแกน y
3 print("R-Squared score", model.score(x_test, y_test)) # R-Square ของการทำนาย
   มีค่าตั้งแต่ 0.1 - 1 (x100)
4 print("ความแม่นยำ %.2f%%" % (model.score(x_test, y_test) * 100))
5
```

The output of the code cell is:

```
[13]: ✓ 0.3s
... Coefficients: [[1.11515152]]
    Intercept: [35.34545455]
    R-Squared score 0.7848301193755732
    ความแม่นยำ 78.48%
```

Below the code cell, there is a section titled "6.การวาดกราฟแสดงผลลัพธ์ของโมเดล".

The bottom of the notebook shows a terminal window with the following commands and output:

```
>>> from joblib import load
>>> from sklearn.linear_model import LinearRegression
>>> myModel = load('G:\TrainingWorkshop\PythonMLCPF\MyModelTrained\salary_food_model.joblib')
>>> myModel.predict([[35],[60]])
array([[ 74.37575758],
       [102.25454545]])
>>> print("Score:",myModel.score([[17],[18]],[[54],[56]]))
Score: 0.7848301193755732
>>>
```

The status bar at the bottom indicates "Jupyter Server: Local", "Ln 5, Col 1", "Cell 6 of 19", and "Go Live".

```
1  # import libraries
2  import streamlit as st
3  from joblib import load
4
5  # load model from disk
6  model = load('salary_food_model.joblib')
7
8  # Create Streamlit Web App
9  st.title('Food Expenses Prediction App')
10
11 # Add an input field for income
12 income = st.number_input('Enter your income:')
13
14 # Add prediction button
15 predict_button = st.button('Predict')
16
17 # Get predictions and display results
18 if predict_button:
19     # Reshape the input data into a 2D array
20     input_data = [[income/1000]]
21
22     # Make predictions using the model
23     prediction = model.predict(input_data)[0]
24
25     # Display the prediction food expenses
26     st.write("Prediction food expenses: ", round(prediction, 2))
```

• LIVE

รับชมฟรี



#5

พื้นฐาน

แมชชีนเลิร์นนิ่ง

PYTHON

for Machine Learning

อัปเดตปี

2024



อาจารย์สามิตร
สถาบันไอทีจีเนียส

12 FEB 2024 20.30-22.30 PM

วันที่

PYTHON

for Machine Learning

5


AI



อ.สาวิตร โทยม



สถาบันไอทีจีเนียส



Module 8

โมเดล Logistic Regression



- พื้นฐานคณิตศาสตร์สำหรับ Logistic Regression
- ลักษณะของ Logistic Regression
- การทำนายผลด้วย Scikit-Learn
- Confusion Matrix
- การประเมินโมเดล (Model Evaluation)
- ค่า Threshold
- ROC Curve และ AUC Score

การวิเคราะห์การถดถอยด้วย Logistic Regression Model

เป็นโมเดลที่ใช้ทำนายความน่าจะเป็นของเหตุการณ์ เช่น ผ่าน/ไม่ผ่าน ชนะ/แพ้ สุขภาพดี/ป่วย รอดชีวิต/ตาย อีกทั้งยังสามารถขยายการใช้งานสำหรับแยกแยะประเภทหรือหมวดหมู่ได้ เช่น แยกสัตว์ สุนัข แมว เสือ

โมเดลนี้ถูกนำไปใช้งานด้านต่าง ๆ เช่น ทำนายอัตราการเสียชีวิตในผู้ป่วยที่ได้รับบาดเจ็บ การประเมินความรุนแรงของผู้ป่วย และการทำนายความเสี่ยงการเกิดโรค

Logistic Regression



ลักษณะของ Logistic Regression

Logistic Regression เป็นโมเดลที่จัดอยู่ในประเภท Supervise Learning สำหรับการทำนายผลแบบ Classification ถึงแม้ชื่อโมเดลจะลงท้ายด้วยคำว่า Regression ก็ตาม โดยข้อมูลตัวอย่างแต่ละรายการจะมีคอลัมน์ที่เป็น Target (หรือผลลัพธ์ หรือตัวแปรตาม : y) ที่สามารถจำแนกประเภทหรือแบ่งได้เป็น 2 กลุ่ม เช่น Yes/No, True/False, Success/Fail, High/Low, Male/Female, R/X, 1/0 เป็นต้น ส่วนคอลัมน์ที่เป็น Feature หรือตัวแปรอิสระ (x) อาจมีตั้งแต่ 1 คอลัมน์ขึ้นไป เช่นเดียวกับ Linear Regression ซึ่งลักษณะข้อมูลที่สามารถใช้การทำนายแบบ Logistic Regression

x	y
5.5	No
6.5	Yes
8.1	Yes
3.2	No
7.5	Yes

x1	x2	y
8	6	1
3	5	0
4	9	0
5	8	1
9	9	1


ลักษณะของ Logistic Regression

หลักการของ Logistic Regression คือ การนำค่าของคอลัมน์ Feature หรือตัวแปรอิสระ ($x_1, x_2, x_3, \dots$) ไปคำนวณในแบบเดียวกับสมการ Linear Regression เช่น

$$P(x) = \frac{1}{1 + e^{-(\beta_0 + \sum \beta_i x_i)}}$$

ลักษณะสมการนี้เอง จึงเป็นที่มาของคำว่า Logistic Regression เพราะ e ยกกำลังสมการแบบ Linear Regression นั้นเอง หรือกล่าวได้ว่า Logistic Regression ก็คือการหาความน่าจะเป็นด้วย Sigmoid Function ทั้งนี้หากเราทราบค่า intercept และ coefficient ก็สามารถนำตัวแปรอิสระ $x_1, x_2, \dots$ มาแทนค่าในฟังก์ชัน ก็จะได้ค่าความน่าจะเป็นออกมา แต่อย่างไรก็ตาม ความน่าจะเป็นต้องมีค่าระหว่าง 0 - 1 ในขณะที่ผลลัพธ์ของ Logistic Regression จะต้องอยู่ในรูปแบบ Classification ที่จำแนกได้ 2 กลุ่ม เช่น Yes/No ซึ่งไม่สอดคล้องกัน ดังนั้น จึงต้องนำค่าความน่าจะเป็นที่ได้ไปทำการเปรียบเทียบต่อ

ลักษณะของ Logistic Regression



- ถ้าความน่าจะเป็นมีค่าระหว่าง 0 - 0.5 จะทำนายผลเป็นคลาสกลุ่มที่ 1
- ถ้าความน่าจะเป็นมีค่าระหว่าง 0.5 - 1 จะทำนายผลเป็นคลาสกลุ่มที่ 2

ตัวอย่างที่ 8.1: ทำนายผลจากข้อมูลในตารางดังภาพ

x1	x2	y
8	6	yes
3	5	no
4	9	no
5	8	yes
9	9	yes

```
from sklearn.linear_model import LogisticRegression
```

```
model = LogisticRegression()
```

```
x = [[8, 6], [3, 5], [4, 9], [5, 8], [9, 9]] #[[x1, x2], ...]
```

```
y = ['yes', 'no', 'no', 'yes', 'yes']
```

```
model.fit(x, y)
```

```
#ทำนายผลเมื่อ x1=4, x2=4, y=? และ x1=5, x2=5, y=?
```

```
x_predict = [[4, 4], [5, 5]]
```

```
y_predict = model.predict(x_predict)
```

```
print('ถ้า x = [4, 4], y =', y_predict[0])
```

```
print('ถ้า x = [5, 5], y =', y_predict[1])
```

```
print()
```

```
print('ความน่าจะเป็น')
```

```
prob = model.predict_proba(x_predict)
```

```
print(prob)
```

5	8	yes
9	9	yes

```
ถ้า x = [4, 4], y = no
ถ้า x = [5, 5], y = yes

ความน่าจะเป็น
[[0.69091303 0.30908697]
 [0.46549678 0.53450322]]

1 - P      P
```

Step 1: Import sklearn and logistic regression

```
1 from sklearn.linear_model import LogisticRegression
2 import pandas as pd
3
4 # Create Object LogisticRegression
5 model = LogisticRegression()
```

[57] ✓ 0.3s

Python

Step 2: Import / Create DataSet

```
1 x = [[8, 6], [3, 5], [4, 9], [5, 8], [9, 9]]
2 y = ['yes', 'no', 'no', 'yes', 'yes']
3
4 df = pd.DataFrame({'x1,x1':x, 'y':y})
5 df
6
```

[58] ✓ 0.3s

Python

...

	x1,x1	y
0	[8, 6]	yes
1	[3, 5]	no
2	[4, 9]	no
3	[5, 8]	yes
4	[9, 9]	yes

Step 3: Train Model

```
[59] 1 model.fit(x, y) 0.4s Python
```

...

- ▼ LogisticRegression
- LogisticRegression()

Step 4: Prediction

```
[66] 1 #ทำนายผลเมื่อ x1=4, x2=4, y=? และ x1=5, x2=5, y=?
      2 x_predict = [[4, 4], [5, 5]]
      3
      4 y_predict = model.predict(x_predict)
      5 print('ถ้า x = [4, 4], y =', y_predict[0])
      6 print('ถ้า x = [5, 5], y =', y_predict[1]) 0.3s Python
```

...

ถ้า x = [4, 4], y = no
ถ้า x = [5, 5], y = yes

Step 5: Probability

```
1 print('ความน่าจะเป็น')
2 prob = model.predict_proba(x_predict)
3 print(prob)
```

[67] ✓ 0.3s Python

... ความน่าจะเป็น
[[0.69091303 0.30908697]
 [0.46549678 0.53450322]]

ตัวอย่างที่ 8.2: ทำนายการซื้อขายสินค้า

ร้านค้าออนไลน์แห่งหนึ่งได้จัดเก็บข้อมูลของผู้ที่เข้า สมัครสมาชิกของร้านไว้ในไฟล์ Excel แล้วพบว่า เพศ อายุ และเงินเดือน มีผลต่อการสั่งซื้อสินค้า โดยข้อมูลบางส่วนเป็นดังภาพ ซึ่งเราจะใช้ในการทดสอบเพื่อหา Confusion Matrix และค่าที่เกี่ยวข้องต่าง ๆ เพื่อประเมินโมเดลดังที่เราได้ศึกษามา

- คอลัมน์ gender เป็นสตริง และมีผลต่อการสั่งซื้อ ดังนั้นต้องเข้ารหัสเป็นตัวเลข
- ตัวเลขของคอลัมน์ salary จะแตกต่างจากคอลัมน์ gender และ age เป็นอย่างมาก ดังนั้นเราต้อง ปรับสเกลให้อยู่ในเกณฑ์ที่ใกล้เคียงกัน ดังแนวทางที่เคยทำกันมา

	gender	age	salary	purchased
0	Male	19	19000	0
1	Male	35	20000	0
2	Female	26	43000	0
3	Female	27	57000	0
4	Male	19	76000	0
...	...	...	...	...
395	Female	46	41000	1
396	Male	51	23000	1
397	Female	50	20000	1
398	Male	36	33000	0
399	Female	49	36000	1
400 rows × 4 columns				

ตัวอย่างที่ 8.2: ทำนายการซื้อขายหุ้น

Step 1: Import pandas and scikit-learn

```
1 import pandas as pd
2 from sklearn.linear_model import LogisticRegression
3 from sklearn.preprocessing import LabelEncoder, StandardScaler
4 from sklearn.model_selection import train_test_split
5 from sklearn.metrics import confusion_matrix, accuracy_score, precision_score, recall_score, f1_score
```

[35] ✓ 0.4s

Python

ตัวอย่างที่ 8.2: ทำนายการซื้อขายสินค้า

Step 2: Load DataSet to Pandas

```
1 !pip install openpyxl
2 !pip install openpyxl
```

Python

```
1 # Load Excel file to pandas
2 df = pd.read_excel(r'datasets/customer.xlsx')
3 df
```

Python

	gender	age	salary	purchased
0	Male	19	19000	0
1	Male	35	20000	0
2	Female	26	43000	0
3	Female	27	57000	0
4	Male	19	76000	0
...	...	...	...	...
395	Female	46	41000	1
396	Male	51	23000	1
397	Female	50	20000	1
398	Male	36	33000	0
399	Female	49	36000	1

400 rows × 4 columns

ตัวอย่างที่ 8.2: ทำนายการซื้อขายสินค้า

Step 3: Encoding gender column

```
1 encoder = LabelEncoder()  
2 df['gender'] = encoder.fit_transform(df['gender'])
```

[9] ✓ 0.3s

Python

Step 4: Define Feature data

```
1 features = ['gender', 'age', 'salary']  
2 x = df[features].values  
3 y = df['purchased'].values
```

[17] ✓ 0.4s

Python

Step 5: Split data for Training and Test

```
1 x_train, x_test, y_train, y_test = train_test_split(x, y, random_state=0)💡
```

[18] ✓ 0.3s

Python

ตัวอย่างที่ 8.2: ทำนายการซื้อขายสินค้า

Step 6: Scale after splitting

```
1 scaler = StandardScaler()  
2 x_train = scaler.fit_transform(x_train)  
3 x_test = scaler.transform(x_test)
```

[19] ✓ 0.4s

Python

Step 7: Create Model and train

```
1 model = LogisticRegression()  
2 model.fit(x_train, y_train)
```

[20] ✓ 0.4s

Python

...

```
▼ LogisticRegression  
LogisticRegression()
```

ตัวอย่างที่ 8.2: ทำนายการซื้อขาย

Step 8: Prepare data for Test

```
1 #ข้อมูลที่จะทำนายผล
2 gender = 'Male'
3 gender_enc = encoder.transform([gender]) #ต้องเข้ารหัส
4 age = 45
5 salary = 45000
6
7 x_pred = [[gender_enc, age, salary]]
8 x_pred_sc = scaler.transform(x_pred) #ต้องปรับสเกล
9 💡
10 print(x_pred)
11 print(x_pred_sc)
```

[27] ✓ 0.5s

Python

```
... [[array([1]), 45, 45000]]
    [[ 1.02020406  0.68068169 -0.71274813]]
```

<__array_function__ internals>:180: VisibleDeprecationWarning: Creating an ndarray from ragged nested sequences (which is a list-or-tuple of lists-or-tuples-or ndarrays with different lengths or shapes) is deprecated. If you meant to do this, you must specify 'dtype=object' when creating the ndarray.

ตัวอย่างที่ 8.2: ทำนายการซื้อขายสินค้า

Step 9: Prediction

```
1 y_pred = model.predict(x_pred_sc)
2
3 y_pred
4
5 #คอลัมน์ purchased เก็บค่า 0/1 จึงเทียบเป็นข้อความที่เข้าใจได้
6
7 print('Prediction:')
8 p = 'Not Purchase' if y_pred[0] == 0 else 'Purchase'
9 print(f'gender: {gender}, age: {age}, salary: {salary} ==>', p)
10
```

[31] ✓ 0.6s

Python

```
... Prediction:
gender: Male, age: 45, salary: 45000 ==> Not Purchase
```

ตัวอย่างที่ 8.2: ทำนายการซื้อขายสินค้า

Step 10: Model Evaluation

```
1 y_pred_test = model.predict(x_test)
2
3 print('Confusion Matrix:')
4 cfm = confusion_matrix(y_test, y_pred_test)
5 print(cfm)
6
7 print('Accuracy:', '{:.2f}'.format(accuracy_score(y_test, y_pred_test)))
8 print('Precision:', '{:.2f}'.format(precision_score(y_test, y_pred_test)))
9 print('Recall:', '{:.2f}'.format(recall_score(y_test, y_pred_test)))
10 print('F1 Score:', '{:.2f}'.format(f1_score(y_test, y_pred_test)))
11
```

[43] ✓ 0.3s

Python




```
... Confusion Matrix:
[[65  3]
 [ 7 25]]
Accuracy: 0.90
Precision: 0.89
Recall: 0.78
F1 Score: 0.83
```

ค่า Threshold

เราได้ทราบไปแล้วว่า Logistic Regression จะใช้หลักการคำนวณความน่าจะเป็นในแบบ Sigmoid Function ซึ่งจะได้ค่าระหว่าง 0 - 1 จากนั้นก็ใช้ค่าความน่าจะเป็นที่ระดับ 0.5 ในการแบ่งคลาส เช่น Yes/No โดยเราเรียกตัวเลขที่ใช้เป็นเกณฑ์สำหรับแบ่งคลาสว่า Threshold หรือจุด Cut-Off และตามปกติจะถูกกำหนดไว้ที่ 0.5 หรือเป็นค่าดีฟอลต์นั่นเอง ทั้งนี้หากเราปรับค่า Threshold ให้สูงหรือต่ำกว่า 0.5 การทำนายผลบางส่วนอาจเปลี่ยนแปลงไปจากเดิม

การกำหนด Threshold ที่ระดับ 0.4, 0.5 และ 0.8 (สมมติให้คลาสที่อยู่เหนือเส้นแบ่ง Threshold เป็นกลุ่ม Positive และนับตั้งแต่เส้นแบ่งลงมาเป็นกลุ่ม Negative)

ค่า Threshold



จากภาพจะเห็นได้ว่า เมื่อกำหนดค่า Threshold ที่แตกต่างกันออกไป การทำนายบางส่วนก็จะต่างกัน ออกไปด้วย อย่างไรก็ตาม จำนวน Positive/Negative ที่แสดงในภาพนั้น เป็นเพียงการทำนายผลตามความน่าจะเป็นที่คำนวณได้ แต่ไม่ใช่ผลการทำนาย ดังนั้น ถึงแม้จำนวน Positive หรือ Negative จะเพิ่มขึ้น แต่ส่วนที่เพิ่มมานั้น เมื่อนำไปเทียบกับ Actual อาจมีทั้งอันที่ทำนายถูกและผิด

ตัวอย่างที่ 8.3: ทำสายพันธุ์ของดอก iris

iris setosa



petal

sepal

iris versicolor



petal

sepal

iris virginica




petal

sepal

Dataset (ชุดข้อมูล)

คือ การนำข้อมูลที่มีคุณสมบัติเหมือนกันมาจัดเป็นชุดให้ถูกต้องตามลักษณะโครงสร้างข้อมูล โดยชุดข้อมูลพื้นฐานที่ใช้กันอย่างแพร่หลายทางด้าน Machine Learning ได้แก่ชุดข้อมูลดอกไม้ (Iris Dataset) กับ ชุดข้อมูลลายมือตัวเลขอารบิก (MNIST Dataset)

1.ชุดข้อมูลดอกไม้ (Iris Dataset) เป็นชุดข้อมูลพื้นฐานที่ใช้กันอย่างแพร่หลายในด้านสถิติและ Machine Learning โดยชุดข้อมูลดอกไม้ประกอบไปด้วยดอกไม้ 3 สายพันธุ์ได้แก่ Versicolor , Setosa , Virginica ดังภาพประกอบด้านล่าง



Dataset (ชุดข้อมูล)

คุณสมบัติหรือ Feature ในชุดข้อมูลดอกไม้

คือการวัดความกว้างและความยาวของกลีบใบที่เรียกว่า Sepal (กลีบเลี้ยง) และ Petal (กลีบดอก) (มีหน่วยเป็นเซนติเมตร cm.)

iris setosa



petal

sepal

iris versicolor



petal

sepal

iris virginica




petal

sepal

Dataset (ชุดข้อมูล)

ตัวอย่างการเก็บชุดข้อมูลดอกไม้



	A	B	C	D	E
1	Sepal Length	Sepal Width	Petal Length	Petal Width	Class
2	5.1	3.5	1.4	0.2	Iris-setosa
3	4.9	3	1.4	0.2	Iris-setosa
4	4.7	3.2	1.3	0.2	Iris-setosa
5	4.6	3.1	1.5	0.2	Iris-setosa
6	5	3.6	1.4	0.2	Iris-setosa
7	5.4	3.9	1.7	0.4	Iris-setosa
8	4.6	3.4	1.4	0.3	Iris-setosa
9	5	3.4	1.5	0.2	Iris-setosa
10	4.4	2.9	1.4	0.2	Iris-setosa
11	4.9	3.1	1.5	0.1	Iris-setosa
12	5.4	3.7	1.5	0.2	Iris-setosa
13	4.8	3.4	1.6	0.2	Iris-setosa
14	4.8	3	1.4	0.1	Iris-setosa
15	4.3	3	1.1	0.1	Iris-setosa
16	5.8	4	1.2	0.2	Iris-setosa
17	5.7	4.4	1.5	0.4	Iris-setosa
18	5.4	3.9	1.3	0.4	Iris-setosa
19	5.1	3.5	1.4	0.3	Iris-setosa
20	5.7	3.8	1.7	0.3	Iris-setosa
21	5.1	3.8	1.5	0.3	Iris-setosa
22	5.4	3.4	1.7	0.2	Iris-setosa
23	5.1	3.7	1.5	0.4	Iris-setosa
24	4.6	3.6	1	0.2	Iris-setosa
25	5.1	3.3	1.7	0.5	Iris-setosa

- **Class Label / Target** คือ ชื่อข้อมูลที่ต้องการทราบเป็นผลลัพธ์ (Output) เช่น ชื่อสายพันธุ์ดอกไม้ 3 ชนิด
- **Attribute / Features** คือ คุณสมบัติของดอกไม้แต่ละสายพันธุ์ (ความยาว ความสูง หน่วยเซนติเมตร)

ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 0: Install seaborn

```
1 !pip install seaborn
```

Python

Step 1: Import lib

```
1 import matplotlib.pyplot as plt
2 import seaborn as sns
3 import pandas as pd
4 from sklearn.linear_model import LogisticRegression
5 # from sklearn.datasets import load_iris
6 from sklearn.model_selection import train_test_split
7 from sklearn.metrics import accuracy_score
```

[27] ✓ 0.2s

Python

ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 2: Load DataSet

```
1 df = sns.load_dataset('iris')
2 df.tail(30)
3 # data = load_iris()
4 # df = pd.DataFrame(data['data'], columns=data['feature_names'])
5 # df['target'] = data['target']
6 # df
```

[46]

✓ 0.4s

Python

...	sepal_length	sepal_width	petal_length	petal_width	species
120	6.9	3.2	5.7	2.3	virginica
121	5.6	2.8	4.9	2.0	virginica
122	7.7	2.8	6.7	2.0	virginica
123	6.3	2.7	4.9	1.8	virginica
124	6.7	3.3	5.7	2.1	virginica
125	7.2	3.2	6.0	1.8	virginica
126	6.2	2.8	4.8	1.8	virginica
127	6.1	3.0	4.9	1.8	virginica
128	6.4	2.8	5.6	2.1	virginica
129	7.2	3.0	5.8	1.6	virginica
130	7.4	2.8	6.1	1.9	virginica
131	7.9	3.8	6.4	2.0	virginica
132	6.4	2.8	5.6	2.2	virginica

ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 3: Data Cleansing

Step 4: Choose Feature and Label Field

Feature==>sepal length (cm), sepal width (cm), petal length (cm), petal width (cm)

Label==>target

ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 5: Scatter Plot


```
1 plt.figure(figsize=(8,6))  
2 sns.scatterplot(x='sepal_length', y='sepal_width', hue='species', data=df)
```

[37] ✓ 0.2s

Python

... <AxesSubplot: xlabel='sepal_length', ylabel='sepal_width'>

</>



ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 6: Split Data with Train and Test

```
1 x = df.iloc[:, :-1] # ไม่เอาคอลัมน์สุดท้ายไว้เป็น feature
2 y = df.iloc[:, -1] # เลือกเอาเฉพาะฟิลด์สุดท้ายเป็น label
3
4 x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2) # 80% / 20 %
5 print(x_test)
```

[106] ✓ 0.8s

Python

... Output exceeds the [size limit](#). Open the full output data [in a text editor](#)

	sepal_length	sepal_width	petal_length	petal_width
118	7.7	2.6	6.9	2.3
67	5.8	2.7	4.1	1.0
17	5.1	3.5	1.4	0.3
29	4.7	3.2	1.6	0.2
25	5.0	3.0	1.6	0.2
80	5.5	2.4	3.8	1.1
138	6.0	3.0	4.8	1.8
4	5.0	3.6	1.4	0.2
51	6.4	3.2	4.5	1.5
90	5.5	2.6	4.4	1.2
88	5.6	3.0	4.1	1.3
37	4.9	3.6	1.4	0.1
23	5.1	3.3	1.7	0.5
87	6.3	2.3	4.4	1.3
148	6.2	3.4	5.4	2.3
144	6.7	3.3	5.7	2.5
111	6.4	2.7	5.3	1.9
99	5.7	2.8	4.1	1.3
76	6.0	2.8	4.0	1.0

ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 7: Create Object LogisticRegression และ Train Model

```
1 model = LogisticRegression()  
2 model.fit(x_train, y_train)  
3
```

[96] ✓ 0.4s

Python

```
... g:\TrainingWorkshop\PythonMLClass\env\lib\site-packages\sklearn\linear_model\_logistic.py:444: ConvergenceWarning: lbfgs  
failed to converge (status=1):  
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

Increase the number of iterations (max_iter) or scale the data as shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

```
n_iter_i = _check_optimize_result(
```

</>

▼ LogisticRegression

LogisticRegression()

ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 8: Test Model

```
1 predict = model.predict(x_test)
2 print(predict)
3 print(y_test)
```

[111] ✓ 0.3s

Python

... Output exceeds the [size limit](#). Open the full output data [in a text editor](#)

```
['virginica' 'versicolor' 'setosa' 'setosa' 'setosa' 'versicolor'
'virginica' 'setosa' 'versicolor' 'versicolor' 'versicolor' 'setosa'
'setosa' 'versicolor' 'virginica' 'virginica' 'virginica' 'versicolor'
'versicolor' 'setosa' 'virginica' 'versicolor' 'virginica' 'setosa'
'setosa' 'virginica' 'setosa' 'virginica' 'setosa' 'virginica']
118    virginica
67    versicolor
17      setosa
29      setosa
25      setosa
80    versicolor
138   virginica
4      setosa
51    versicolor
90    versicolor
88    versicolor
37      setosa
23      setosa
87    versicolor
148   virginica
```

ตัวอย่างที่ 8.3: ทำนายสายพันธุ์ของดอก iris

Step 9: Model Evaluation

```
1 # ประเมินความแม่นยำของโมเดล
2 accuracy_score(predict, y_test)
3
```

[114] ✓ 0.4s

Python


... 1.0





PREDICT TITANIC SURVIVAL RATE PYTHON











A "Titanic" Myth: Would Jack Have Survived if Rose Had Shared the Door?



Science Channel

ผู้ติดตาม 4.73 ล้าน คน

ติดตาม

👍 1 แสน



➦ แชร์

Work Flow



Data



Data pre processing



Data Analysis



Train Test split



Logistic Regression model



Evaluation

Titanic Dataset

	index	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
	0	0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	None	S
	1	1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
	2	2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	None	S
	3	3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
	4	4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	None	S
	...	...	...	...	...	...	...	...	...	...	...	...	...	...
	886	886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.0000	None	S
	887	887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S
	888	888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.4500	None	S
	889	889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.0000	C148	C
	890	890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.7500	None	Q
891 rows × 13 columns														

Titanic Dataset

	Index	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	None	S
1	1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	None	S
3	3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	None	S
...	...	...	...	...	...	...	...	...	...	...	...	...	...
886	886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.0000	None	S
887	887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S
888	888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.4500	None	S
889	889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.0000	C148	C
890	890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.7500	None	Q
891 rows × 13 columns													

คอลัมน์	ประเภทข้อมูล	รายละเอียด
PassengerId	เลขจำนวนเต็ม	รหัสประจำตัวผู้โดยสาร
Survived	เลขจำนวนเต็ม	รอดชีวิต (1) หรือเสียชีวิต (0)
Pclass	เลขจำนวนเต็ม	ชั้นโดยสาร (1 = ชั้นหนึ่ง, 2 = ชั้นสอง, 3 = ชั้นสาม)
Name	อักขร	ชื่อผู้โดยสาร
Sex	อักขร	เพศ (M = ชาย, F = หญิง)
Age	เลขจำนวนเต็ม	อายุ
SibSp	เลขจำนวนเต็ม	จำนวนพี่น้องและ/หรือคู่สมรสบนเรือ
Parch	เลขจำนวนเต็ม	จำนวนพ่อแม่และ/หรือลูกบนเรือ
Ticket	อักขร	หมายเลขตั๋ว
Fare	เลขจำนวนเต็ม	ค่าโดยสาร
Cabin	อักขร	หมายเลขห้องโดยสาร
Embarked	อักขร	ท่าเรือที่ขึ้นเรือ (C = เซาแธมป์ตัน, S = เซาท์แฮมป์ตัน, Q = เซอร์บูร์ก)

Menu

[Home](#)

Titanic Survival Prediction

Age



SibSp



Parch



Fare



Predict

Prediction

Not Survived

Prediction Probability:

Survived: 0.46

Did not survive: 0.54

• LIVE

รับชมฟรี



#6

พื้นฐาน

แมชชีนเลิร์นนิ่ง

PYTHON

for Machine Learning

อัปเดตปี

2024



อาจารย์สามิตร
สถาบันไอทีจีเนียส

26 FEB 2024 20.30-22.30 PM

วันที่

PYTHON

for Machine Learning

6


AI



อ.สาวิตร โทยม



สถาบันไอทีจีเนียส



Module 9

โมเดล K-Nearest Neighbors


- การคำนวณระยะห่างและความเหมือน
- ลักษณะของโมเดล K-Nearest Neighbors (KNN)
- การทำนายผลด้วย Scikit-Learn
- การปรับสเกลข้อมูล
- ข้อมูลแบบ Multiclass
- โมเดล KNN แบบ Regression
- การเลือกค่า K ที่เหมาะสม (Optimal K)

โมเดล K-Nearest Neighbors

K-Nearest Neighbors น่าจะเป็นโมเดลที่ง่ายที่สุดอีกอันหนึ่งของ Machine Learning เพราะใช้วิธีการคำนวณด้วยหลักการคณิตศาสตร์ระดับพื้นฐานเท่านั้น แต่ให้ผลลัพธ์ที่มีความถูกต้อง แม่นยำ เชื่อถือได้โดยเนื้อหาในบทนี้ เราจะได้เรียนรู้ทั้งหลักการในเบื้องต้นของ K-Nearest Neighbors ทั้งการทำนายผลแบบ Classification และ Regression รวมถึงการใช้งานผ่าน Scikit-Learn อีกด้วย

การคำนวณระยะห่างและความเหมือน


ก่อนที่เราจะเข้าสู่การเรียนรู้เกี่ยวกับโมเดล K-Nearest Neighbors ในหัวข้อต่อ ๆ ไป ก็ควรทราบ หลักการคำนวณระยะห่างที่เป็นพื้นฐานของกับโมเดลนี้เอาไว้ล่วงหน้า ซึ่งจะช่วยให้เราเข้าใจแนวคิดต่าง ๆ ได้ดียิ่งขึ้น โดยการวัดระยะห่างระหว่าง 2 จุดบนแกน X และ Y สามารถใช้สมการยุคลิด (Euclidean Distance) ที่มีรูปแบบทั่วไปคือ



โมเดล K-Nearest Neighbors

การคำนวณระยะห่างและความเหมือน

เช่น สมมติว่าเราต้องการคำนวณหาระยะห่างระหว่างจุดต่าง ๆ ดังภาพถัดไป ก็มีวิธีการดังนี้



อย่างไรก็ตาม ใน Scikit-Learn มีฟังก์ชัน `euclidean_distances()` สำหรับการคำนวณระยะห่างระหว่างจุดมาให้เราใช้งานโดยตรงอยู่แล้ว

โมเดล K-Nearest Neighbors

การหาระยะห่างโดยใช้ฟังก์ชัน `euclidean_distances()` ของ Scikit-Learn

```
from sklearn.metrics.pairwise import euclidean_distances
#กำหนดจุดพิกัดแบบลิสต์ 2 มิติ
a = [[3, 4]]      #จุด a (x, y)
b = [[8, 13]]     #จุด b
c = [[14, 5]]     #จุด c

print('dist_ab =', euclidean_distances(a, b)) #ระยะห่างระหว่างจุด a และ b
print('dist_bc =', euclidean_distances(b, c)) #ระยะห่างระหว่างจุด b และ c
print('dist_ac =', euclidean_distances(a, c)) #ระยะห่างระหว่างจุด a และ c
```


การคำนวณระยะห่างดังที่กล่าวมานี้ เราสามารถนำไปเปรียบเทียบ เพื่อจัดกลุ่มข้อมูลโดยการเทียบระดับความเหมือน (Similarity) ด้วยหลักการ ดังนี้

ระยะห่างมาก => ความเหมือนจะน้อย

ระยะห่างน้อย => ความเหมือนจะมาก

หรือกล่าวได้ว่า ระดับความเหมือนจะแปรผกผันกับระยะห่างนั่นเอง

```
dist_ab = [[10.29563014]]
dist_bc = [[10.]]
dist_ac = [[11.04536102]]
```



ลักษณะของโมเดล K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN) เป็นโมเดลสำหรับการทำนายผลอีกแบบหนึ่งของ Machine Learning ที่เข้าใจได้ง่ายกว่าโมเดลอื่นๆ ดังนั้น จึงสามารถเรียนรู้ได้ในระยะเวลาอันสั้น ซึ่งลักษณะเด่นที่น่าสนใจของ KNN คือ


- ใช้วิธีเปรียบเทียบระยะห่างของตำแหน่งข้อมูล ด้วยหลักการทางคณิตศาสตร์ขั้นพื้นฐานเท่านั้น จึงไม่ต้องการใช้เวลาในการศึกษาเรียนรู้มากนัก
- รองรับการทำนายผลทั้งแบบ Classification (จัดกลุ่มข้อมูล) และแบบ Regression (ผลลัพธ์เป็นตัวเลข)
- รองรับการทำนายผลแบบ Multi-Class (ข้อมูลผลลัพธ์มีมากกว่า 2 กลุ่ม)
- มีเสถียรภาพและความคงทนในการทำงานค่อนข้างมาก
- มีความยืดหยุ่นต่อการปรับเปลี่ยนข้อมูลตัวอย่างได้ดี
- โมเดล KNN สามารถทำนายผลข้อมูลที่คลาสแต่ละกลุ่มมีการกระจายข้อมูลแบบปะปนกันจนอาจจะยุ่งยากต่อการใช้โมเดลอื่นๆ

ลักษณะของโมเดล K-Nearest Neighbors (KNN)

อย่างไรก็ตาม โมเดล KNN ก็มีข้อบกพร่องในบางลักษณะ เช่น หากมีข้อมูลตัวอย่างเป็นจำนวนมาก การทำนายผลอาจช้ากว่าโมเดลอื่น รวมถึงปัญหาการเลือกค่า K ที่เหมาะสม นอกจากนี้ก็ยังไม่เหมาะกับข้อมูลที่มีหลายมิติอีกด้วย แต่เมื่อเทียบกับข้อดีแล้ว ข้อเสียเหล่านี้ก็เป็นสิ่งที่ยอมรับได้ ดังนั้น KNN จึงเป็นโมเดลที่นิยมใช้กันอย่างแพร่หลาย เพราะนอกจากความง่ายแล้วยังให้ผลการทำนายที่เชื่อถือได้อีกด้วย และเนื่องจากโมเดล KNN นั้น รองรับการทำนายผลทั้งแบบ Classification และแบบ Regression ซึ่งในที่นี้จะกล่าวถึงทั้ง 2 แบบ โดยในช่วงแรกจะเริ่มจากแบบ Classification ก่อน ส่วนแบบ Regression จะกล่าวถึงในภายหลัง

หลักการของโมเดล KNN แบบ Classification คือ จะเปรียบเทียบความเหมือน (Similarity) ของตำแหน่งข้อมูลที่จะทำนายผลกับตำแหน่งข้อมูลที่อยู่รอบๆ (Neighbors) ว่าอยู่ใกล้กับอันใดมากที่สุด (Nearest) ก็จะถือว่าตำแหน่งที่ทำนายผลเป็นคลาสเดียวกับตำแหน่งที่ใกล้ที่สุด นั้น เช่นในภาพ

จากภาพ ถ้าจุดสีเหลี่ยมคือตำแหน่งข้อมูลที่เราจะทำนายผล ซึ่งอยู่ใกล้กับตำแหน่งของคลาส B มากกว่า A ดังนั้น ตามหลักการของ KNN จะถือว่าจุดสีเหลี่ยมเป็นคลาส B



ต่อไปสมมติว่า เรามีชุดข้อมูลดังในตาราง ซึ่งเมื่อนำมาวาดกราฟแล้วลองประเมินระยะห่างด้วยสายตาแบบง่ายๆ จะเห็นได้ว่า รูปดาวอยู่ใกล้กับตำแหน่งที่ 4 มากที่สุดและตำแหน่งนี้เป็นคลาส A ดังนั้น ผลการทำนายจึงเป็นคลาส A

ตัวอย่าง K-Nearest Neighbors (KNN)

สมมติว่าเรามีข้อมูลขนาดเล็กที่แสดงความสัมพันธ์ระหว่างส่วนสูง น้ำหนัก และขนาดเสื้อเชิ้ตที่ใส่ ดังตารางในภาพด้านขวามือ ถ้านำมา Train Model แบบ KNN สำหรับการทำนายผล โดยใช้ Scikit-Learn ก็จะได้ดังนี้

	Height_cms	Weight_kgs	T_Shirt_Size
0	158	58	M
1	158	59	M
2	160	64	L
3	163	64	L
...	...	...	...
14	170	63	L
15	163	61	M
16	170	64	L
17	170	68	L

18 rows × 3 columns

ตัวอย่าง K-Nearest Neighbors (KNN)

```
import pandas as pd
from sklearn.neighbors import KNeighborsClassifier

df = pd.read_excel(r'data\shirt_size.xlsx')
# with pd.option_context('display.max_rows', 8):
# display(df)

x = df[['Height_cms', 'Weight_kgs']]
y = df['T-Shirt_Size']

k = 5
model = KNeighborsClassifier(n_neighbors=k)
model.fit(x, y)


x_pred = [[161, 61]]
y_pred = model.predict(x_pred)

h = x_pred[0][0]
w = x_pred[0][1]
s = y_pred[0]

print('K =', k)
print(f'Height: {h}, Weight: {w}, T-Shirt Size => {s}')
print('Accuracy:',
      '{:.2f}'.format(model.score(x, y)))
```


K = 5
Height: 161, Weight: 61, T-Shirt Size => M
Accuracy: 0.89

ตัวอย่าง การเปลี่ยนค่า K



จากภาพ ถ้าเราให้ตำแหน่งที่จะทำนายผล (รูปดาว) เป็นจุดศูนย์กลาง แล้วลากเส้นรอบวงล้อมรอบตำแหน่งดังกล่าว โดยให้มีจำนวนตำแหน่งภายในบริเวณวงกลมเท่ากับค่า K ก็จะได้ผลการทำนายดังนี้

- K = 1 เราพิจารณตำแหน่งข้างเคียงที่ใกล้ที่สุดเพียงอันเดียว ดังนั้น ตำแหน่งรูปดาวจึงทำนายผลว่าเป็นคลาส A
- K = 3 จะพิจารณตำแหน่งข้างเคียงที่ใกล้ที่สุดทั้งหมด 3 อัน ซึ่งจากภาพ
 - จำนวนคลาส A = 1
 - จำนวนคลาส B = 2
 - จำนวนคลาส B > A แสดงว่าตำแหน่งรูปดาวจะทำนายผลว่าเป็นคลาส B
- K = 5 จะพิจารณตำแหน่งข้างเคียงที่ใกล้ที่สุดทั้งหมด 5 อัน ซึ่งจากภาพ
 - จำนวนคลาส A = 3
 - จำนวนคลาส B = 2
 - จำนวนคลาส A > B แสดงว่าตำแหน่งรูปดาวจะทำนายผลว่าเป็นคลาส A



โมเดล KNN และ Regression

```
import pandas as pd
from sklearn.neighbors import KNeighborsRegressor
from sklearn.preprocessing import StandardScaler
```

```
k = 3
model = KNeighborsRegressor(n_neighbors=k)
model.fit(x, y)
```

```
x_pred = [[170, 40]]
```

```
K = 3
Height: 170, Age: 40 => Weight: 59.00
Accuracy: 0.87
```

	Features		Targets
	A	B	C
1	height	age	weight
2	150	45	77
3	155.75	26	47
4	170.68	30	55
5	179.83	34	59
6	146.3	40	72
7	176.78	36	60
8	161.54	19	40
9	176.78	28	60
10	167.64	23	45
11	170.68	32	58

โมเดล KNN แบบ Regression

1. Import Library ที่จำเป็น

```
1 import pandas as pd
2 from sklearn.neighbors import KNeighborsRegressor
3 from sklearn.preprocessing import StandardScaler
4
```

[1]

✓ 0.9s

Python

โหลด KNN และ Regression

2.Load DataSet of pandas

```
1 df = pd.read_excel(r'datasets/height_age_weight.xlsx')  
2   
3 df
```

[2]

✓ 0.2s

Python

...

	height	age	weight
0	150.00	45	77
1	155.75	26	47
2	170.68	30	55
3	179.83	34	59
4	146.30	40	72
5	176.78	36	60
6	161.54	19	40
7	176.78	28	60
8	167.64	23	45
9	170.68	32	58

โมเดล KNN และ Regression

3. Choose Feature and Target and Scale

```
1 scaler = StandardScaler()  
2  
3 x = df[['height', 'age']].values # Feature  
4 x = scaler.fit_transform(x)  
5 y = df['weight'].values # Target  
6  
7 print(x)  
8 print(y)  
9
```

[4] ✓ 0.5s

Python

```
... [[-1.40209466  1.84046046]  
     [-0.88523068 -0.71200295]  
     [ 0.45681786 -0.17464223]  
     [ 1.27930575  0.36271849]  
     [-1.73468539  1.16875956]  
     [ 1.00514312  0.63139884]  
     [-0.36477113 -1.65238421]  
     [ 1.00514312 -0.44332259]  
     [ 0.18355413 -1.11502349]  
     [ 0.45681786  0.09403813]]  
[77 47 55 59 72 60 40 60 45 58]
```

โมเดล KNN และ Regression

4. Set K value and Create KNeighborsClassifier Object

```
1 k = 3
2 model = KNeighborsRegressor(n_neighbors=k)
3
```

[5] ✓ 0.3s

Python

5. Train Model

```
1 model.fit(x, y)
2
```

[6] ✓ 0.2s

Python

...

▼ KNeighborsRegressor

KNeighborsRegressor(n_neighbors=3)

โมเดล KNN และ Regression

6. Prediction

```
1 x_pred = [[170, 40]]
2 x_pred_sc = scaler.transform(x_pred)
3 y_pred = model.predict(x_pred_sc)
4
5 h = x_pred[0][0]
6 a = x_pred[0][1]
7 w = '{:.2f}'.format(y_pred[0])
8
9 print('K=', k)
10 print(f'Height: {h}, Age: {a} ⇒ Weight: {w}')
11
```

[9] ✓ 0.3s

Python

```
... K = 3
Height: 170, Age: 40 ⇒ Weight: 59.00
```

โมเดล KNN และ Regression

7. Model Evaluation

```
1 print('K =', k)
2 print(f'Height: {h}, Age: {a} ⇒ Weight: {w}')
3 print('Accuracy: ', '{:.2f}'.format(model.score(x, y)))
4
```


[11] ✓ 0.5s

Python

```
... K = 3
Height: 170, Age: 40 ⇒ Weight: 59.00
Accuracy: 0.87
```



การเลือกค่า K ที่เหมาะสม (Optimal K)

เนื่องจากโมเดล KNN นั้น เราต้องระบุค่า K ซึ่งเป็นจำนวนตำแหน่งข้างเคียงที่อยู่ใกล้ที่สุด ทั้งนี้ การใช้ค่า K ที่แตกต่างกัน ก็จะมีผลต่อการทำนายด้วยตามที่เราได้เรียนรู้มาแล้ว ดังนั้น จึงมักจะเกิดคำถามว่า **เราควร ใช้ค่า K เท่าไหร่จึงจะเหมาะสม** ซึ่งโดยทั่วไปแล้ว เรามักจะเลือกค่า K ที่มีระดับความแม่นยำ (Accuracy หรือ Score) ของการทำนายผลสูงสุด อย่างไรก็ตาม สำหรับโมเดล KNN นั้น ระดับความแม่นยำมักจะมีค่าสูงสุดเมื่อ $K = 1$ (อาจไม่ใช้กับข้อมูลทุกชุดเสมอไป)



แต่เมื่อพิจารณาตามหลักความเป็นจริงแล้ว การใช้ค่า $K = 1$ อาจจะ น้อยเกินไปที่จะตัดสินใจโดยใช้ข้อมูลเพียงตำแหน่งเดียว ดังนั้น เราจึงมักจะใช้วิธีการเปรียบเทียบความแม่นยำของการทำนายผลเมื่อกำหนดค่า K ที่แตกต่างกัน โดยนำมาวาดกราฟที่แสดงความสัมพันธ์ระหว่างค่า K และ ความแม่นยำ (Accuracy) ดังแนวทางในภาพถัดไป (ซ้าย) ซึ่งจะเห็นได้ว่า ระดับความแม่นยำมีแนวโน้มจะขึ้น ไปสูงสุดเมื่อ $K = 7$ นั้นแสดงว่า การทำนายผลของข้อมูลชุดนี้ ควรเลือกค่า $K = 7$ น่าจะเหมาะสมที่สุด

นอกจากนี้ แหล่งข้อมูลบางแห่งได้แนะนำว่า หากมีรายการข้อมูลตัวอย่างเป็นจำนวนมาก และเราแบ่งออกเป็นชุด Training/Testing ก็อาจตรวจสอบความแม่นยำของข้อมูลทั้ง 2 ชุดนี้แยกกัน แล้วนำมาวาดกราฟเพื่อเปรียบเทียบสำหรับหาค่า K ที่เหมาะสมที่สุด



การเลือกค่า K ที่เหมาะสม (Optimal K)



การใช้ค่า $k=1$ กับโมเดล k-Nearest Neighbors (KNN) อาจส่งผลเสียหลายประการ ดังนี้:

1. ความไวต่อค่าผิดปกติ (Outlier Sensitivity):

- KNN ค้นหาเพื่อนบ้านที่ใกล้ที่สุด k ตัวอย่างเพื่อจำแนกประเภทข้อมูลใหม่
- ค่า $k=1$ หมายถึง เพื่อนบ้านเพียงตัวเดียวมีอิทธิพลต่อการจำแนกประเภท
- หากเพื่อนบ้านตัวนั้นเป็นค่าผิดปกติ ผลลัพธ์จะผิดพลาด

2. ความแปรปรวนสูง (High Variance):

- โมเดล KNN มีความแปรปรวนตามจำนวนเพื่อนบ้าน
- ค่า $k=1$ หมายถึง โมเดลไวต่อการเปลี่ยนแปลงของข้อมูล
- การเปลี่ยนแปลงเล็กน้อยในชุดข้อมูลอาจส่งผลต่อผลลัพธ์อย่างมาก

3. ประสิทธิภาพต่ำ (Low Performance):

- ค่า $k=1$ จำกัดข้อมูลที่ใช้ในการจำแนกประเภท
- โมเดลอาจละเลยข้อมูลสำคัญ ส่งผลต่อความแม่นยำ

4. ปัญหา overfitting:

- KNN ที่ใช้ค่า $k=1$ มีแนวโน้มที่จะ overfit กับชุดข้อมูล training
- โมเดลอาจจำแนกประเภทข้อมูล training ได้ดี แต่ทำงานได้ไม่ดีกับข้อมูลใหม่

5. การเลือกเพื่อนบ้านที่ไม่เหมาะสม:

- ค่า $k=1$ จำกัดตัวเลือกเพื่อนบ้าน
- โมเดลอาจเลือกเพื่อนบ้านที่อยู่ไกลหรือไม่เกี่ยวข้อง ส่งผลต่อความแม่นยำ

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

มีผู้สำรวจข้อมูลเพื่อเปรียบเทียบลักษณะของ ผลไม้ 4 ชนิดคือ แอปเปิล ส้ม ส้มแป้น และมะนาว โดยข้อมูล บางส่วนเป็นดังตารางในภาพ เราจะใช้วิธีการของ KNN เพื่อทำนายผลแบบ Multiclass

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.neighbors import KNeighborsClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
```

```
df = pd.read_excel(r'datasets/fruit_data.xlsx')
```

```
x = df[['width', 'height', 'mass', 'color_score']]
y = df['fruit_name']
```

```
k = 5
model = KNeighborsClassifier(n_neighbors=k)
model.fit(x_train, y_train)
```

1	width	height	mass	color_score	fruit_name
2	8.4	7.3	192	0.55	apple
3	6.2	4.7	86	0.8	mandarin
4	6	4.6	84	0.79	mandarin
5	8	6.8	180	0.59	apple
6	7.4	7.2	176	0.6	apple
7	5.8	4.3	80	0.77	mandarin
8	5.9	4.3	80	0.81	mandarin
9	5.8	4	76	0.81	mandarin
10	7.1	7.8	178	0.92	apple
11	7.4	7	172	0.89	apple
12	6.9	7.3	166	0.93	apple
13	7.1	7.6	172	0.92	apple
14	7	7.1	154	0.88	apple
15	7.3	7.7	164	0.7	apple
16	7.6	7.3	152	0.69	apple
17	7.7	7.1	156	0.69	apple
18	7.6	7.5	156	0.67	apple
19	7.5	7.6	168	0.73	apple
20	7.5	7.1	162	0.83	apple
21	7.4	7.2	162	0.85	apple
22	7.5	7.5	160	0.86	apple

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

1. Import Library ที่จำเป็น

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 from sklearn.neighbors import KNeighborsClassifier
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.model_selection import train_test_split
6
```

[1] ✓ 1.8s

Python

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

2.Load DataSet of pandas

```
1 df = pd.read_excel(r'datasets/fruit_data.xlsx')
2 print(df[:5])
3 print(df[-5:])
4
```

[10] ✓ 0.5s

Python

```
...   width  height  mass  color_score  fruit_name
0     8.4     7.3   192         0.55      apple
1     6.2     4.7    86         0.80    mandarin
2     6.0     4.6    84         0.79    mandarin
3     8.0     6.8   180         0.59      apple
4     7.4     7.2   176         0.60      apple
   width  height  mass  color_score  fruit_name
54     6.5     8.5   152         0.72      lemon
55     6.1     8.1   118         0.70      lemon
56     7.6     8.2   180         0.79     orange
57     7.2     7.2   154         0.82     orange
58     7.2    10.3   194         0.70      lemon
```

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

3.Choos Feature and Target

```
1 x = df[['width', 'height', 'mass', 'color_score']]
2 y = df['fruit_name']
3
4 print(x[:5])
5 print(y[:5])
6
```

[27] ✓ 0.3s

Python

```
...   width  height  mass  color_score
0     8.4     7.3   192         0.55
1     6.2     4.7    86         0.80
2     6.0     4.6    84         0.79
3     8.0     6.8   180         0.59
4     7.4     7.2   176         0.60
0      apple
1  mandarin
2  mandarin
3      apple
4      apple
Name: fruit_name, dtype: object
```

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

4.Split DataSet for Train and Test

```
1 x_train, x_test, y_train, y_test = train_test_split(x, y, random_state=0)
2
3 print(x_train[:5])
4 print(x_test[:5])
5
```

[31] ✓ 0.5s

Python

```
...      width  height  mass  color_score
42      7.2     9.2   186         0.72
48      6.0     7.5   116         0.72
7       5.8     4.0    76         0.81
14      7.6     7.3   152         0.69
32      7.2     7.0   164         0.80
      width  height  mass  color_score
26      9.6     9.2   362         0.74
35      7.1     7.9   150         0.75
43      7.3    10.2   216         0.71
28      6.7     7.1   140         0.72
11      7.1     7.6   172         0.92
```

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

5. Scaling

```
1 #scaling after splitting
2 scaler = StandardScaler()
3 x_train = scaler.fit_transform(x_train)
4 x_test = scaler.transform(x_test)
5 print(x_train[:5])
6 print(x_test[:5])
7
```

[42]

✓ 0.4s

Python

```
... [[ 0.15191331  1.17500985  0.49402838 -0.54959973]
      [-1.33346127 -0.0950875  -0.83837741 -0.54959973]
      [-1.5810237  -2.70999381 -1.59975214  0.66627453]
      [ 0.64703817 -0.24451072 -0.15314015 -0.95489115]
      [ 0.15191331 -0.46864555  0.07527227  0.53117739]]
[[ 3.12266247  1.17500985  3.84407721 -0.27940545]
 [ 0.02813209  0.20375893 -0.19120888 -0.14430831]
 [ 0.27569452  1.92212593  1.06505943 -0.68469687]
 [-0.46699277 -0.39393394 -0.38155257 -0.54959973]
 [ 0.02813209 -0.02037589  0.22754722  2.15234308]]
```

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

6. Set K value and Create KNeighborsClassifier Object

```
1 k = 1
2 model = KNeighborsClassifier(n_neighbors=k)
3
```

[54] ✓ 0.3s

Python

7. Train Model

```
1 model.fit(x_train, y_train)
2
```

[55] ✓ 0.3s

Python

...

```
▼ KNeighborsClassifier
KNeighborsClassifier(n_neighbors=1)
```

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

8. Prediction

```
1 x_pred = [[7.5, 7.5, 175, 0.75]]
2 x_pred_sc = scaler.transform(x_pred)
3 y_pred = model.predict(x_pred_sc)
4
5 w = x_pred[0][0]
6 h = x_pred[0][1]
7 m = x_pred[0][2]
8 c = x_pred[0][3]
9 f = y_pred[0]
10
11 print('K =', k)
12 print('Prediction:')
13
14 print(f'width: {w}, height: {h}, mass: {m}, ', end='')
15 print(f'color score {c} ⇒ fruit: {f}')
16
```

[56] ✓ 0.3s

Python

```
... K = 1
Prediction:
width: 7.5, height: 7.5, mass: 175, color score 0.75 ⇒ fruit: orange
```

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)

9.Model Evaluation

```
1 print('Accuracy:', '{:.2f}'.format(model.score(x_test, y_test)))  
2
```

[58] ✓ 0.3s

Python

... Accuracy: 0.87

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)


✓ 10.Optimal K

```
1 acc_train = []
2 acc_test = []
3 n_neighbors = range(1, 11) #1 - 10
4
5 for k in n_neighbors:
6     model = KNeighborsClassifier(n_neighbors=k)
7     model.fit(x_train, y_train)
8     acc_train.append(model.score(x_train, y_train))
9     acc_test.append(model.score(x_test, y_test))
10
11 # Plot train and test
12 plt.plot(n_neighbors, acc_train, 'r-', label='train')
13 plt.plot(n_neighbors, acc_test, 'b--', label='test')
14 plt.xlabel('K-Neighbors')
15 plt.ylabel('Accuracy')
16 plt.legend(loc='best')
17 plt.show()
18
```

[59] ✓ 0.4s

Python

ตัวอย่าง Workshop การเลือกค่า K ที่เหมาะสม (Optimal K)



จากกราฟ แสดงว่าค่า K ที่เหมาะสมของข้อมูลชุดนี้น่าจะอยู่ที่ประมาณ **3 - 5**



อาจารย์สามิตร โกยม

สถาบันไอทีจีเนียส



samitkoyom@gmail.com



iamsamit



faacebook.com/iamsamit



twitter.com/iamsamit



github.com/iamsamitdev



linkedin.com/in/samit-koyom-72173348